

Nguyen Quoc Huy

Synergistic Co-Training of Temporal and Frequency Domains for Semi-Supervised Time Series Learning

VAASAN AMMATTIKORKEAKOULU
UNIVERSITY OF APPLIED SCIENCES
Bachelor of Engineering Information Technology

CoFT: A DUAL-BRANCH, SEMI-SUPERVISED LEARNING FRAMEWORK FOR TIME SERIES
ANALYSIS VIA CROSS-DOMAIN CO-TRAINING

NGUYEN QUOC HUY

Thesis July 2024

Supervisor: Tommi Rintala Vaasa University of Applied Sciences VAMK

ABSTRACT

Author: Nguyen Quoc Huy Title of the thesis: CoFT: A Dual-Branch, Semi-Supervised Learning Framework for Time Series Analysis via Cross-Domain Co-Training Year: 2024 Language: English Number of pages: [Will be updated] Supervisor: Tommi Rintala

Sự gia tăng mạnh mẽ của dữ liệu chuỗi thời gian trong nhiều lĩnh vực, từ IoT công nghiệp đến y tế, đang đối mặt với một nút thắt quan trọng: sự khan hiếm dữ liệu được gán nhãn¹², vốn là yếu tố thiết yếu để huấn luyện các mô hình học sâu mạnh mẽ³⁴. Thách thức này đặc biệt rõ rệt trong các lĩnh vực y tế quan trọng, nơi việc chú thích các tín hiệu phức tạp như điện não đồ (EEG)^{5...} hoặc điện tâm đồ (ECG)⁸⁹ tốn kém, mất thời gian và đòi hỏi chuyên môn sâu^{3...}. Các phương pháp gán nhãn truyền thống "tốn kém và không thực tế"¹⁰ và "không thực tế cho các ứng dụng quy mô lớn"¹². Để giải quyết nghịch lý "dữ liệu phong phú, nhãn khan hiếm" này, luận văn giới thiệu CoFT (Co-training with Frequency and Temporal domains), một khung học bán giám sát (semi-supervised learning) mới với kiến trúc hai nhánh¹¹.

CoFT tận dụng các điểm mạnh bổ trợ của miền thời gian và miền tần số bằng cách áp dụng phương pháp đồng huấn luyện (co-training) đích thực¹², trong đó hai nhánh chuyên biệt, có kiến trúc đối xứng, học song song và chủ động "dạy" lẫn nhau thông qua cơ chế gán nhãn giả (pseudo-labeling) được kiểm soát cẩn thận¹³¹⁴. Mỗi quan hệ học tập cộng sinh này nhằm mục đích xây dựng các biểu diễn dữ liệu toàn diện và mạnh mẽ hơn so với các phương pháp chỉ sử dụng một miền¹⁵.

Kết quả thực nghiệm cho thấy CoFT nhất quán và vượt trội đáng kể so với mô hình cơ sở CA-TCC tiên tiến nhất, đạt được mức tăng độ chính xác đáng kể (ví dụ: +8.17% trên bộ dữ liệu HAR và +9.32% trên Sleep-EDF trong các kịch bản với chỉ 1% dữ liệu có nhãn) [Dựa trên cuộc trò chuyện trước]. Đặc biệt, nghiên cứu đã khám phá ra hiện tượng "Less is More", tiết lộ rằng giá trị siêu thấp của trọng số đồng huấn luyện (ví dụ: 0.0001) là tối ưu, giúp ngăn chặn hiện tượng "nhằm lẫn nhãn" phát sinh từ sự khớp nối quá mạnh với các nhãn giả nhiễu. Phát hiện này đóng góp khoa học quan trọng vào việc hiểu động lực học của co-training trong học sâu cho chuỗi thời gian, khẳng định CoFT là một giải pháp mạnh mẽ và hiệu quả trong các môi trường dữ liệu khan hiếm nhãn [Dựa trên cuộc trò chuyện trước].

Keywords: Time Series Analysis, Semi-Supervised Learning, Self-Supervised Learning, Co-Training, Deep Learning, Frequency Domain, Contrastive Learning, Label Scarcity.

MỤC LỤC

- [TÓM TẮT](#)
- [DANH MỤC HÌNH ẢNH](#)
- [DANH MỤC BẢNG BIỂU](#)
- [CÁC TỪ VIẾT TẮT](#)
- [BẢNG KÝ HIỆU](#)
- [1 GIỚI THIỆU](#)
 - [1.1 Thách thức về sự khan hiếm nhãn trong phân tích chuỗi thời gian hiện đại](#)
 - [1.2 Mục tiêu và Câu hỏi nghiên cứu của luận văn](#)
 - [1.2.1 Mục tiêu của luận văn](#)
 - [1.2.2 Câu hỏi nghiên cứu](#)
 - [1.3 Cấu trúc luận văn](#)
 - [1.4 Việc sử dụng trí tuệ nhân tạo trong luận văn này](#)
- [2 NỀN TẢNG KIẾN THỨC VÀ LÝ THUYẾT](#)
 - [2.1 Các mô hình học từ dữ liệu có nhãn hạn chế](#)
 - [2.2 Học tự giám sát: Nghệ thuật học từ chính dữ liệu](#)
 - [2.2.1 Các chiến lược tăng cường dữ liệu](#)
 - [2.2.2 Hàm mất mát NT-Xent: Phân tích sâu về mặt toán học](#)
 - [2.2.3 Mô hình cơ sở CA-TCC: Một quy trình bán giám sát đa giai đoạn nghiêm ngặt](#)
 - [2.3 Đồng huấn luyện và hợp nhất miền tần số-thời gian](#)
 - [2.3.1 Các phương pháp hợp nhất truyền thống](#)
 - [2.3.2 CoFT: Một khuôn khổ đồng huấn luyện thực sự](#)
 - [2.4 Kết luận: Xây dựng trên một nền tảng vững chắc](#)
- [3 TRIỂN KHAI VÀ PHƯƠNG PHÁP LUẬN](#)
 - [3.1 Hành trình phương pháp luận: Lý giải và thách thức](#)
 - [3.1.1 Lựa chọn chiến trường: Lựa chọn mô hình cơ sở và benchmark](#)
 - [3.1.2 Thử thách về khả năng tái lập: Các rào cản kỹ thuật và dữ liệu](#)
 - [3.2 Các nguyên tắc chỉ đạo cho khả năng tái lập](#)
 - [3.3 Công nghệ và triển khai](#)
 - [3.4 Các bộ dữ liệu benchmark](#)
 - [3.4.1 Nhận dạng hoạt động của con người \(HAR\)](#)
 - [3.4.2 Sleep-EDF \(Phân loại giai đoạn giấc ngủ\)](#)
 - [3.4.3 Epilepsy \(Phát hiện co giật\)](#)
 - [3.4.4 Phương pháp phân chia dữ liệu bán giám sát](#)
 - [3.5 Khuôn khổ CoFT: Kiến trúc và quy trình](#)
 - [3.5.1 Kiến trúc hai nhánh: Thiết kế và triển khai](#)
 - [3.5.2 Hàm mất mát hỗn hợp: Phân tích chi tiết](#)

- [3.5.3 Quy trình huấn luyện sáu giai đoạn: Công thức từng bước](#)
 - [3.5.4 Tăng cường dữ liệu](#)
- [4 KẾT QUẢ VÀ PHÂN TÍCH](#)
 - [4.1 Trả lời câu hỏi nghiên cứu 1: CoFT có thể vượt trội hơn một mô hình cơ sở tiên tiến không?](#)
 - [4.2 Trả lời câu hỏi nghiên cứu 2: Nguồn gốc thực sự của sự cải thiện hiệu suất là gì?](#)
 - [4.3 Trả lời câu hỏi nghiên cứu 3: Hành trình nghiên cứu để chuyển giao kiến thức tối ưu](#)
 - [4.3.1 Giả thuyết ban đầu và những thất bại đầu tiên: Nguy cơ của sự liên kết mạnh](#)
 - [4.3.2 Khám phá "Ít hơn là Nhiều hơn": Một cuộc điều tra có hệ thống](#)
 - [4.3.3 Động lực của phương pháp tổ hợp: Hiện tượng "Lật ngược"](#)
 - [4.4 Trả lời câu hỏi nghiên cứu 4: Các nguyên tắc có thể được chuyển giao sang các bộ dữ liệu mới không?](#)
- [5 KẾT LUẬN](#)
 - [5.1 Tóm tắt hành trình nghiên cứu](#)
 - [5.2 Hạn chế của nghiên cứu](#)
 - [5.3 Hướng nghiên cứu trong tương lai](#)
 - [5.4 Suy ngẫm cuối cùng](#)
- [TÀI LIỆU THAM KHẢO](#)
- [PHỤ LỤC](#)
 - [Phụ lục A: Bảng cấu hình siêu tham số](#)

DANH MỤC HÌNH ẢNH

Hình 1: Học tương phản hai mục tiêu trong TS-TCC. Mô hình học cách bất biến với các phép tăng cường thông qua Tương phản Thời gian và nhạy cảm với cấu trúc thời gian thông qua Tương phản Ngữ cảnh.

Hình 2: Tổng quan cấp cao về khuôn khổ CoFT, cho thấy các nhánh Thời gian và Tần số song song, và mô-đun đồng huấn luyện trung tâm.

Hình 3: Kiến trúc của khối Transformer được sử dụng trong cả hai bộ mã hóa thời gian và tần số.

Hình 4: Cơ chế Tương phản Tần số, minh họa việc sử dụng các phép tăng cường quang phổ và bộ mã hóa chuyên dụng.

Hình 5: Chiến lược huấn luyện đa pha, được điều chỉnh từ CA-TCC, minh họa quy trình bốn giai đoạn làm nền tảng cho CoFT.

DANH MỤC BẢNG BIỂU

Bảng 1. Nghiên cứu cắt lớp các thành phần trong TS-TCC và CA-TCC.

Bảng 2. Hiệu suất cuối cùng của CoFT so với mô hình cơ sở CA-TCC.

Bảng 3. Phân tích thống kê về sự cải thiện hiệu suất.

Bảng 4. Nghiên cứu cắt lớp - Phân tích sự cải thiện hiệu suất của CoFT.

- Bảng 5. Ảnh hưởng của trọng số đồng huấn luyện (λ_{ct}) đến độ chính xác trên HAR 1%.
- Bảng 6. Tương tác giữa phương pháp tổ hợp và trọng số đồng huấn luyện.
- Bảng 7. Các tham số được chuyển giao và lý do.
- Bảng 8. Các tham số huấn luyện và mô hình chung.
- Bảng 9. Các siêu tham số dành riêng cho CoFT.
- Bảng 10. Các tham số học tương phản và tăng cường dữ liệu.

CÁC TỪ VIẾT TẮT

Viết tắt	Tên đầy đủ
CoFT	Đồng huấn luyện với miền Tần số và Thời gian (Co-training with Frequency and Temporal domains)
SSL	Học Tự giám sát (Self-Supervised Learning)
CA-TCC	Tăng cường Tương phản - Phân cụm Tương phản Thời gian (Contrastive Augmentation - Temporal Contrastive Clustering)
TS-TCC	Tương phản Thời gian và Ngữ cảnh (cho Chuỗi thời gian) (Temporal and Contextual Contrasting)
FFT	Biến đổi Fourier nhanh (Fast Fourier Transform)
HAR	Nhận dạng hoạt động của con người (Human Activity Recognition)
EEG	Điện não đồ (Electroencephalogram)
ECG	Điện tâm đồ (Electrocardiogram)
PSG	Đa ký giấc ngủ (Polysomnography)
REM	Chuyển động mắt nhanh (Rapid Eye Movement)
InfoTS	Tăng cường Chuỗi Thời gian dựa trên Lý thuyết Thông tin (Information-Theoretic Time Series Augmentation)
NT-Xent	Cross-Entropy chuẩn hóa theo nhiệt độ (Normalized Temperature-scaled Cross-Entropy)
SupCon	Học Tương phản có giám sát (Supervised Contrastive Learning)

BẢNG KÝ HIỆU

Ký hiệu	Mô tả
(λ_{ct})	Trọng số đồng huấn luyện: Siêu tham số kiểm soát ảnh hưởng của mất mát đồng huấn luyện. Khám phá "Ít hơn là Nhiều hơn" cho thấy giá trị cực thấp (0.0001) là tối ưu.
(λ_{cs})	Trọng số nhất quán: Siêu tham số kiểm soát mất mát nhất quán đặc trưng giữa nhánh thời gian và tần số.
(L_{total})	Tổng hàm mất mát hỗn hợp được sử dụng để huấn luyện mô hình CoFT.
$(L_{cotraining})$	Thành phần mất mát bắt nguồn từ các nhãn giả được tạo ra bởi nhánh đối diện.
$(L_{supervised})$	Mất mát phân loại có giám sát tiêu chuẩn (ví dụ: Cross-Entropy).
(τ)	Nhiệt độ: Một tham số tỷ lệ được sử dụng trong hàm mất mát tương phản (NT-Xent) và softmax để kiểm soát độ sắc nét của phân phối xác suất.
(y_{true})	Các nhãn thực tế được cung cấp trong bộ dữ liệu.
(y_{pseudo})	Các nhãn được tạo ra bởi một nhánh của mô hình để huấn luyện nhánh còn lại.
(θ)	Đại diện cho các tham số có thể học được của mô hình mạng nơ-ron.

1 GIỚI THIỆU

1.1 Thách thức về sự khan hiếm nhãn trong phân tích chuỗi thời gian hiện đại

Trong những năm gần đây, học sâu đã nổi lên như một lực lượng mang tính cách mạng trong phân tích chuỗi thời gian, đạt được hiệu suất tiên tiến trong các nhiệm vụ từ nhận dạng hoạt động của con người đến dự báo tài chính. Tuy nhiên, sức mạnh của các mô hình này được xây dựng trên một nền tảng quan trọng và thường rất tốn kém: các bộ dữ liệu lớn, được gán nhãn chính xác. Mặc dù sự gia tăng của các cảm biến, thiết bị IoT và hồ sơ kỹ thuật số đã dẫn đến một sự bùng nổ về khối lượng dữ liệu chuỗi thời gian thô, quá trình gán nhãn có ý nghĩa vẫn là một nút thắt cổ chai đáng kể. Mô hình "dữ liệu giàu, nhãn nghèo" này đòi hỏi một sự chuyển dịch khỏi các phương pháp hoàn toàn có giám sát sang các mô hình học tập có thể khai thác hiệu quả tiềm năng to lớn, chưa được khai thác của dữ liệu không có nhãn.

Vấn đề khan hiếm nhãn trở nên đặc biệt nghiêm trọng trong các lĩnh vực mà dữ liệu không chỉ phức tạp mà còn nhạy cảm và đòi hỏi chuyên môn sâu để diễn giải. Ví dụ, trong **chăm sóc sức khỏe**, việc chú thích các tín hiệu điện não đồ (EEG) để phân loại giai đoạn giấc ngủ hoặc phát hiện co giật đòi hỏi các nhà thần kinh học được đào tạo phải dành hàng giờ để xem xét tỉ mỉ các bản ghi. Tương tự, việc gán nhãn dữ liệu điện tâm đồ (ECG) để phân loại rối loạn nhịp tim đòi hỏi con mắt tinh tường của một bác sĩ tim mạch. Quá trình này không chỉ chậm và tốn kém mà còn có thể mang tính chủ quan, dẫn đến sự thay đổi giữa những người đánh giá. Trong **sản xuất công nghiệp**, việc gán nhãn dữ liệu cảm biến để dự đoán hỏng hóc máy móc thường đòi hỏi phải đợi một sự cố thực tế xảy ra, vốn là những sự kiện hiếm và tốn kém. Trong những môi trường có yêu cầu cao này, việc không thể tận dụng hiệu quả lượng lớn dữ liệu không có nhãn thể hiện một cơ hội bị bỏ lỡ cho khám phá khoa học và đổi mới thực tế.

Để giải quyết khoảng trống nghiên cứu cơ bản này, luận văn này hướng đến mô hình học bán giám sát, nhằm mục đích học từ các bộ dữ liệu chứa một lượng nhỏ dữ liệu có nhãn và một lượng lớn dữ liệu không có nhãn. Cụ thể, chúng tôi tập trung vào phương pháp tiền huấn luyện tự giám sát, nơi một mô hình trước tiên học các biểu diễn mạnh mẽ và có thể tổng quát hóa từ kho dữ liệu không có nhãn thông qua các nhiệm vụ ban đầu (pretext tasks). Công trình này giới thiệu **CoFT (Đồng huấn luyện với miền Tần số và Thời gian)**, một khuôn khổ hai nhánh mới được thiết kế để tối đa hóa việc trích xuất thông tin từ dữ liệu chuỗi thời gian trong môi trường khan hiếm nhãn này. Giả thuyết cốt lõi của CoFT là miền thời gian (cách một tín hiệu phát triển theo thời gian) và miền tần số (các thành phần tuần hoàn tạo nên tín hiệu) cung cấp các góc nhìn bổ sung và hiệp đồng về dữ liệu. Thay vì chỉ đơn thuần hợp nhất các miền này thành các đặc trưng, CoFT thực hiện một phương pháp **đồng huấn luyện** thực sự, trong đó hai nhánh chuyên biệt—mỗi nhánh cho một miền—học song song và tích cực "dạy" lẫn nhau thông qua

một cơ chế gán nhãn giả được kiểm soát cẩn thận. Bằng cách tạo ra một mối quan hệ học tập cộng sinh giữa hai miền này, CoFT nhằm mục đích xây dựng một biểu diễn dữ liệu toàn diện và mạnh mẽ hơn so với việc mỗi miền hoạt động riêng lẻ.

1.2 Mục tiêu và Câu hỏi nghiên cứu của luận văn

1.2.1 Mục tiêu của luận văn

Luận văn này chủ yếu nhằm mục đích thiết kế, xác thực và phân tích toàn diện khuôn khổ **CoFT (Đồng huấn luyện với miền Tần số và Thời gian)**. Mục tiêu trung tâm là đánh giá cách kiến trúc hai miền, bán giám sát mới này hoạt động so với một mô hình cơ sở mạnh, tiên tiến (CA-TCC), đặc biệt là trong các kịch bản khan hiếm nhãn.

Để đạt được điều này, nghiên cứu sẽ tiến hành một loạt các thí nghiệm có kiểm soát để phân tích một cách có hệ thống các nguồn gốc của sự cải thiện hiệu suất. Điều này bao gồm một cách tiếp cận kép:

1. **Đánh giá Hiệu suất:** Một phân tích so sánh giữa CoFT và một mô hình cơ sở CA-TCC được tinh chỉnh nghiêm ngặt để định lượng sự cải thiện hiệu suất ròng.
2. **Phân tích Yếu tố:** Một phân tích sâu thông qua các nghiên cứu cắt lớp để xác định và kiểm tra các yếu tố chính—cả về kiến trúc (ví dụ: cấu trúc hai nhánh, phương pháp tổ hợp) và tham số (ví dụ: siêu tham số đồng huấn luyện)—ảnh hưởng đến hiệu quả của mô hình.

Thông qua cách tiếp cận này, luận văn tìm cách cung cấp một sự hiểu biết sâu sắc hơn, minh bạch hơn về việc triển khai một mô hình đồng huấn luyện hai miền, vượt ra ngoài việc chỉ báo cáo một con số độ chính xác cuối cùng để giải thích *tại sao* nó hoạt động. Cần lưu ý rằng một mục tiêu quan trọng không chỉ là đạt được hiệu suất tiên tiến, mà còn là thiết lập một phương pháp luận nghiêm ngặt để đánh giá các mô hình phức tạp và hiểu các nguyên tắc cơ bản của học tập chéo miền trong chuỗi thời gian.

1.2.2 Câu hỏi nghiên cứu

Luận văn này nhằm trả lời bốn câu hỏi nghiên cứu chính, được thông báo trực tiếp bởi các mục tiêu đã nêu trước đó và được cấu trúc để được trả lời bằng phân tích trong Chương 4:

- **Câu hỏi 1:** Liệu một khuôn khổ đồng huấn luyện hai nhánh (CoFT) tận dụng cả miền thời gian và tần số có thể vượt trội đáng kể và nhất quán so với một mô hình đơn miền, tiên tiến (CA-TCC) trên các bộ dữ liệu chuỗi thời gian benchmark không?
- **Câu hỏi 2:** Nguồn gốc thực sự của sự cải thiện hiệu suất của CoFT là gì? Bao nhiêu phần trăm là do kiến trúc mới so với việc tối ưu hóa siêu tham số nghiêm ngặt?

- **Câu hỏi 3:** Các tham số và cơ chế tối ưu để chuyển giao kiến thức giữa hai miền là gì, và những nguyên tắc cơ bản nào chi phối hiệu quả của chúng (ví dụ: hiện tượng "ít hơn là Nhiều hơn")?
- **Câu hỏi 4:** Liệu các nguyên tắc học được từ một bộ dữ liệu có thể được chuyển giao hiệu quả để hướng dẫn tối ưu hóa trên các bộ dữ liệu mới, đa dạng, đặc biệt là trong lĩnh vực y tế, mà không cần tinh chỉnh lại toàn bộ?

1.3 Nhiệm vụ và Phương pháp luận chi tiết

Hành trình nghiên cứu được trình bày trong luận văn này không phải là một con đường tuyến tính mà là một quá trình xoắn ốc, lặp đi lặp lại và đầy thách thức. Nó phản ánh bản chất thực sự của việc khám phá khoa học, nơi những ý tưởng ban đầu được kiểm tra, thất bại, và tinh chỉnh liên tục. Quy trình này có thể được mô tả chi tiết qua các giai đoạn chính sau:

1. **Giai đoạn Khám phá và Định hình (Exploration and Formulation):** Quá trình bắt đầu bằng một giai đoạn **tra cứu, học tập và khảo sát (survey)** sâu rộng các tài liệu khoa học. Giai đoạn này giống như việc vẽ một bản đồ cho một vùng đất chưa được khám phá, nhằm nắm bắt các xu hướng, các phương pháp luận thống trị và những câu hỏi còn bỏ ngỏ trong lĩnh vực học bán giám sát cho chuỗi thời gian. Từ bức tranh toàn cảnh đó, việc **lựa chọn chủ đề** được thu hẹp dần, và một **khoảng trống nghiên cứu (research gap)** cụ thể, có ý nghĩa đã được xác định: sự thiếu hụt các phương pháp khai thác một cách có hệ thống và hiệu quả thông tin từ nhiều miền (cụ thể là thời gian và tần số) trong một khuôn khổ đồng huấn luyện thực sự, thay vì chỉ hợp nhất chúng như những đặc trưng đơn thuần.
2. **Giai đoạn Nền tảng và Tái lập (Foundation and Reproduction):** Sau khi xác định khoảng trống, một cuộc **tổng quan tài liệu (literature review)** tập trung hơn đã được tiến hành. Giai đoạn này không chỉ dừng lại ở việc đọc. Nhiều bài báo khoa học có mã nguồn mở đã được **tải về và chạy thực nghiệm** để đánh giá tính khả thi, hiểu sâu hơn về kiến trúc và chọn ra một mô hình nền tảng (baseline) mạnh mẽ nhất. Mô hình CA-TCC đã được chọn vì hiệu suất vượt trội và sự rõ ràng trong phương pháp luận. Tuy nhiên, quá trình tái lập này là một thử thách kỹ thuật thực sự. Nó đòi hỏi phải đối mặt và giải quyết vô số vấn đề: từ việc **sửa các lỗi tiềm ẩn trong mã nguồn** đến việc xử lý các **xung đột và sự lỗi thời của các phiên bản gói (package dependencies)**. Quan trọng hơn cả, để đảm bảo **tính công bằng khoa học**, một nỗ lực đáng kể đã được đầu tư để tái tạo chính xác các phương pháp tiền xử lý và phân chia tập dữ liệu mà không có mã nguồn gốc, một bước đi tối quan trọng để có được một phép so sánh "táo với táo" đáng tin cậy.
3. **Giai đoạn Phát triển và Thử nghiệm lặp lại (Iterative Development and Experimentation):** Đây là giai đoạn cốt lõi, tiêu tốn nhiều thời gian và công sức nhất. Dựa trên nền tảng đã được tái lập vững chắc, một giả thuyết ban đầu về cách kết hợp

hai miền đã được hình thành. Quá trình này là một vòng lặp không ngừng của chu trình khoa học: **đặt câu hỏi** ("Làm thế nào để hai miền 'dạy' cho nhau một cách hiệu quả?"), **đưa ra giả thiết giả định** (ví dụ: sử dụng một trọng số đồng huấn luyện lớn để thúc đẩy trao đổi mạnh mẽ), **thử nghiệm bằng mã nguồn**, và sau đó đối mặt với các kết quả không mong muốn (mô hình phân kỳ, hiệu suất giảm sút thảm hại). Mỗi thất bại không phải là một ngõ cụt, mà là một điểm dữ liệu quý giá, thúc đẩy một chu kỳ mới: **tra cứu và nghiên cứu lại**, đọc thêm nhiều bài báo để tìm kiếm những ý tưởng và góc nhìn mới, và tinh chỉnh lại giả thuyết. Quá trình **"lặp lại rồi lại lặp lại"** này, cùng với vô số **vấn đề kỹ thuật không tên khác** (ví dụ: quản lý bộ nhớ GPU, tối ưu hóa thời gian chạy, đảm bảo tính nhất quán của các hạt giống ngẫu nhiên), là điều kiện tiên quyết để dần dần tìm ra hướng đi phù hợp và khám phá ra những nguyên tắc cốt lõi, chẳng hạn như hiện tượng "Ít hơn là Nhiều hơn" đầy phản trực giác.

4. **Giai đoạn Xác thực và Phân tích (Validation and Analysis):** Một khi đã tìm ra một hướng đi đầy hứa hẹn, một loạt các thí nghiệm có cấu trúc, được kiểm soát chặt chẽ đã được thiết kế và thực hiện. Mục tiêu của giai đoạn này là trả lời một cách có hệ thống và thuyết phục các câu hỏi nghiên cứu đã đặt ra. Giai đoạn này đòi hỏi sự tỉ mỉ trong việc ghi lại kết quả, thực hiện các phân tích thống kê (như kiểm định t-test), và diễn giải sâu sắc các phát hiện để rút ra những kết luận khoa học vững chắc, vượt ra ngoài những con số đơn thuần.

1.4 Cấu trúc luận văn

Cấu trúc hiện tại của luận văn là kết quả của một quá trình tái cấu trúc đáng kể. Ban đầu, công trình được soạn thảo theo phong cách "kể chuyện khoa học" (scientific storytelling), một lối viết thường thấy trong các bài báo hội nghị khoa học hàng đầu (Rank A*), tập trung vào việc xây dựng một câu chuyện hấp dẫn và thu hút để trình bày các phát hiện. Tuy nhiên, sau khi tham khảo các quy định và luận văn mẫu của Đại học Khoa học Ứng dụng Vaasa (VAMK), một quyết định quan trọng đã được đưa ra là phải điều chỉnh lại toàn bộ cấu trúc để tuân thủ nghiêm ngặt theo định dạng báo cáo học thuật tiêu chuẩn, có hệ thống và rõ ràng hơn theo yêu cầu của trường.

Do đó, phần còn lại của luận văn này được cấu trúc một cách có hệ thống như sau. **Chương 2** cung cấp một tổng quan toàn diện về các công trình liên quan trong học bán giám sát, các phương pháp tương phản cho chuỗi thời gian, và hợp nhất đa miền, thiết lập nền tảng lý thuyết vững chắc cho công trình của chúng tôi. **Chương 3** đi sâu vào các chi tiết kỹ thuật, trình bày một cách minh bạch kiến trúc CoFT, phương pháp luận, quy trình huấn luyện, và các bộ dữ liệu được sử dụng. **Chương 4** trình bày toàn bộ hành trình thực nghiệm, trả lời một cách có hệ thống từng câu hỏi nghiên cứu với dữ liệu thực nghiệm và phân tích chi tiết. Cuối cùng, **Chương 5** kết luận bằng cách tóm tắt các đóng góp chính, thảo luận về những hạn chế và ý nghĩa rộng hơn của các phát hiện, đồng thời đề xuất các hướng nghiên cứu cụ thể trong tương lai.

1.5 Việc sử dụng trí tuệ nhân tạo trong luận văn này

Trong quá trình thực hiện luận văn này, các công cụ trí tuệ nhân tạo đã được sử dụng như một trợ lý nghiên cứu và soạn thảo, nhưng luôn tuân thủ các nguyên tắc về tính trung thực và khả năng kiểm chứng. Thay vì sử dụng các mô hình AI theo cách tạo sinh tự do, phương pháp tiếp cận chính là **Truy xuất-Tăng cường-Tạo sinh (Retrieval-Augmented Generation - RAG)**. Điều này có nghĩa là AI được yêu cầu đưa ra câu trả lời hoặc hỗ trợ soạn thảo dựa trên một tập hợp các tài liệu khoa học và nguồn thông tin đáng tin cậy đã được cung cấp trước.

Cách tiếp cận này được lựa chọn một cách có chủ ý để:

- **Đảm bảo tính trung thực và có thể kiểm định:** Mọi thông tin do AI hỗ trợ đều có nguồn gốc rõ ràng từ các tài liệu tham khảo, giúp tác giả dễ dàng kiểm tra, đối chiếu và xác thực, loại bỏ nguy cơ sử dụng các thông tin vô căn cứ.
- **Chống lại hiện tượng "ảo giác" (Hallucination):** Bằng cách giới hạn không gian kiến thức của AI trong các tài liệu đã được kiểm duyệt, nguy cơ mô hình "sáng tạo" ra các sự thật không chính xác được giảm thiểu đáng kể.
- **Tránh sự thiếu công bằng và thiên vị:** Việc sử dụng các nguồn tài liệu đa dạng và được đánh giá ngang hàng giúp giảm thiểu sự thiên vị có thể tồn tại trong dữ liệu huấn luyện của các mô hình ngôn ngữ lớn.

Cụ thể, **Gemini** và **Perplexity AI** đã được sử dụng để hỗ trợ tái cấu trúc các đoạn văn, làm rõ các lập luận phức tạp, và tổng hợp thông tin từ các bài báo đã được cung cấp. Vai trò của AI hoàn toàn là một công cụ hỗ trợ, còn toàn bộ nội dung, phân tích, diễn giải và kết luận khoa học trong luận văn đều là sản phẩm trí tuệ của tác giả.

Chắc chắn rồi, chúng ta sẽ đi sâu vào "Nền tảng Kiến thức và Lý thuyết" để làm rõ các khái niệm quan trọng, đặc biệt là CA-TCC và TS-TCC, vốn là cơ sở cho khuôn khổ CoFT.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

Chương này thiết lập nền tảng lý thuyết và bối cảnh nghiên cứu cho khuôn khổ **CoFT**. Mục tiêu của chương không chỉ là liệt kê các khái niệm, mà là xây dựng một lập luận có hệ thống, dẫn dắt người đọc từ những đặc tính cơ bản nhất của dữ liệu chuỗi thời gian đến lý do tại sao một kiến trúc đồng huấn luyện đa miền lại là một

bước tiến hợp lý và cần thiết. Chúng ta sẽ bắt đầu bằng việc phân tích các thuộc tính và thách thức độc nhất của dữ liệu chuỗi thời gian, làm nổi bật sự khác biệt căn bản của nó so với các loại dữ liệu khác. Tiếp theo, chương sẽ đi sâu vào các mô hình học biểu diễn hiện đại, đặc biệt là **Học Tương phản Tự giám sát (Self-Supervised Contrastive Learning)**, và phân tích chi tiết kiến trúc của mô hình nền tảng **CA-TCC** [7]. Cuối cùng, chúng tôi sẽ giới thiệu lý thuyết **đồng huấn luyện (co-training)** [3] như một giải pháp có nguyên tắc để hợp nhất thông tin từ nhiều góc nhìn, tạo tiền đề vững chắc cho kiến trúc CoFT sẽ được trình bày chi tiết trong Chương 3.

2.1. Phân tích Chuỗi thời gian: Một Mô hình Dữ liệu Độc nhất

Học sâu đã đạt được những thành công vang dội trong các lĩnh vực như thị giác máy tính và xử lý ngôn ngữ tự nhiên. Tuy nhiên, việc áp dụng một cách máy móc các kiến trúc thành công từ các lĩnh vực này sang chuỗi thời gian thường không mang lại hiệu quả tối ưu. Nguyên nhân sâu xa nằm ở bản chất độc nhất và những thách thức cố hữu của dữ liệu chuỗi thời gian.

2.1.1. Định nghĩa và Các thành phần Cấu trúc

Về mặt hình thức, một chuỗi thời gian đơn biến là một tập hợp các quan sát $Y=\{y_1, y_2, \dots, y_T\}$ được sắp xếp theo một chỉ số thời gian $t=1, 2, \dots, T$. Khác với các tập dữ liệu thông thường nơi thứ tự các mẫu có thể hoán đổi mà không làm mất thông tin, trong chuỗi thời gian, **thứ tự là thông tin**. Mỗi quan hệ phụ thuộc nhân quả theo thời gian—rằng một quan sát tại thời điểm t bị ảnh hưởng bởi các quan sát trước đó—là thuộc tính cơ bản nhất.

Một chuỗi thời gian cổ điển thường có thể được phân tách thành bốn thành phần cấu trúc chính, cung cấp cái nhìn sâu sắc về các động lực tiềm ẩn của nó:

- **Xu hướng (Trend):** Hướng di chuyển dài hạn, cơ bản của chuỗi. Ví dụ, xu hướng tăng trưởng của GDP một quốc gia trong nhiều thập kỷ hoặc sự suy giảm dần hiệu suất của một cảm biến công nghiệp theo thời gian (sensor drift).
- **Tính thời vụ (Seasonality):** Các mẫu lặp lại có chu kỳ cố định và đã biết. Ví dụ, doanh số bán lẻ tăng vọt vào quý IV hàng năm do các dịp lễ, hoặc mô hình tiêu thụ điện năng cao hơn vào ban ngày và thấp hơn vào ban đêm.
- **Chu kỳ (Cycle):** Các mẫu lặp lại không có chu kỳ cố định, thường kéo dài trong vài năm và liên quan đến các yếu tố kinh tế vĩ mô. Ví dụ, các chu kỳ kinh tế bùng nổ và suy thoái.
- **Thành phần Ngẫu nhiên (Irregularity/Noise):** Các biến động không thể đoán trước, còn lại sau khi đã loại bỏ ba thành phần trên. Đây là phần không có cấu trúc của tín hiệu.

[FIGURE_PLACEHOLDER: Sơ đồ phân tách một chuỗi thời gian thành các thành phần Xu hướng, Thời vụ, Chu kỳ và Ngẫu nhiên. Sử dụng ví dụ về dữ liệu doanh số bán lẻ hàng tháng.]

Việc hiểu và mô hình hóa các thành phần này là rất quan trọng, vì một mô hình hiệu quả phải có khả năng phân biệt giữa các mẫu có cấu trúc (xu hướng, thời vụ) và nhiễu ngẫu nhiên.

2.1.2. Các Thách thức theo Lĩnh vực Cụ thể

Sự đa dạng của các bài toán trong thực tế nhấn mạnh rằng không có một giải pháp "một kích cỡ cho tất cả" trong phân tích chuỗi thời gian. Các đặc tính của dữ liệu thay đổi đáng kể tùy thuộc vào lĩnh vực ứng dụng, đặt ra những thách thức riêng biệt:

- **Dữ liệu Y sinh (EEG, ECG):** Các tín hiệu này thường có tần số lấy mẫu cao, không ổn định (non-stationary), và chứa các **mẫu hình thái (morphological patterns)** tinh tế mang tính chẩn đoán. Một sự biến dạng nhỏ trong hình dạng sóng có thể làm thay đổi hoàn toàn ý nghĩa lâm sàng. Do đó, các mô hình phải cực kỳ nhạy cảm với các chi tiết hình thái cục bộ và có khả năng chống lại nhiễu sinh lý (ví dụ: nhiễu từ cơ, chuyển động mắt).
- **Dữ liệu Tài chính:** Đặc trưng bởi **tính phi ổn định (non-stationarity)** và sự ảnh hưởng mạnh mẽ của các sự kiện bên ngoài (cú sốc ngoại sinh). Các hiện tượng như **"cụm biến động" (volatility clustering)**—nơi các giai đoạn biến động cao và thấp có xu hướng tập trung lại với nhau—đòi hỏi các mô hình có khả năng thích ứng nhanh với sự thay đổi đột ngột của phương sai.
- **Dữ liệu Cảm biến Công nghiệp (IoT):** Thường có tính thời vụ rõ rệt (ví dụ: chu kỳ hoạt động ngày/đêm của nhà máy) nhưng cũng có thể bị ảnh hưởng bởi **sự trôi dạt của cảm biến (sensor drift)** theo thời gian. Các mô hình phải đủ mạnh mẽ để phân biệt giữa một sự thay đổi từ từ, lành tính (trôi dạt) và một sự thay đổi đột ngột, báo hiệu sự cố.

Những thách thức này đòi hỏi các kiến trúc có khả năng nắm bắt các phụ thuộc đa quy mô (multi-scale dependencies) và thích ứng với các đặc tính thống kê thay đổi theo thời gian của dữ liệu.

2.2. Học Biểu diễn cho Chuỗi thời gian: Một Mô hình Độc nhất

Mặc dù cả hai lĩnh vực đều được hưởng lợi từ học sâu, việc áp dụng các kỹ thuật thành công từ Thị giác Máy tính (Computer Vision - CV) sang chuỗi thời gian một cách ngây thơ thường dẫn đến thất bại. Nguyên nhân nằm ở những khác biệt căn bản về bản chất dữ liệu và các tính bất biến mong muốn.

2.2.1. Nghịch lý “Dữ liệu phong phú, Nhãn nghèo nàn”: Động lực cho Học Tự

giám sát

Thách thức lớn nhất và là động lực chính của luận văn này là nghịch lý **"dữ liệu phong phú, nhãn nghèo nàn"**. Trong khi việc thu thập dữ liệu chuỗi thời gian thô ngày càng trở nên dễ dàng nhờ vào sự phổ biến của cảm biến và các thiết bị được kết nối, quá trình gán nhãn lại vô cùng tốn kém và đòi hỏi chuyên môn cao.

- Trong **Thị giác Máy tính**, việc gán nhãn cho hàng triệu hình ảnh có thể được thực hiện thông qua các nền tảng cộng đồng (crowdsourcing) với chi phí tương đối thấp.
- Trong **Phân tích Chuỗi thời gian**, đặc biệt là trong y học, việc gán nhãn cho một tín hiệu EEG dài 30 giây để phân loại giai đoạn giấc ngủ đòi hỏi một chuyên gia y tế được đào tạo bài bản và mất nhiều thời gian.

Nghịch lý này đặc biệt nghiêm trọng trong lĩnh vực chuỗi thời gian và là động lực chính thúc đẩy sự phát triển của các phương pháp học bán giám sát và đặc biệt là **học tự giám sát (Self-Supervised Learning - SSL)**. SSL nhằm mục đích học các biểu diễn (representations) hữu ích và có khả năng tổng quát hóa từ chính kho dữ liệu khổng lồ không có nhãn, trước khi tinh chỉnh chúng trên một lượng nhỏ dữ liệu có nhãn cho nhiệm vụ cụ thể.

2.2.2. Sự khác biệt về các Tính Bất biến (Invariances)

Sự khác biệt cốt lõi giữa CV và chuỗi thời gian nằm ở các loại **tính bất biến** mà một mô hình được kỳ vọng sẽ học.

- Trong **CV**, một mô hình nên **bất biến** với các phép biến đổi như lật, xoay, thay đổi tỷ lệ hoặc thay đổi ánh sáng. Một con mèo vẫn là một con mèo dù nó bị lật ngược hay được chiếu sáng khác đi. Các phép tăng cường dữ liệu trong CV được thiết kế để dạy cho mô hình tính bất biến này.
- Trong **chuỗi thời gian**, nhiều phép biến đổi tương tự sẽ phá hủy hoàn toàn thông tin. Việc "lật" một chuỗi thời gian (đảo ngược thời gian) sẽ phá vỡ cấu trúc nhân quả. Việc hoán vị các điểm dữ liệu sẽ làm mất đi các phụ thuộc thời gian. Tính bất biến trong chuỗi thời gian mang một ý nghĩa khác, tinh tế hơn, chẳng hạn như:
 - **Bất biến với sự co giãn thời gian (Time Warping)**: Một hoạt động "đi bộ" được thực hiện nhanh hơn một chút vẫn là đi bộ.
 - **Bất biến với sự dịch chuyển pha (Phase Shift)**: Một mẫu hình lặp lại bắt đầu muộn hơn một chút vẫn là cùng một mẫu hình.
 - **Bất biến với nhiễu biên độ (Magnitude Noise)**: Một tín hiệu với một chút nhiễu cộng vào vẫn nên được nhận dạng là tín hiệu gốc.


Sự khác biệt cơ bản này đòi hỏi một cách tiếp cận hoàn toàn khác để thiết kế các chiến lược tăng cường dữ liệu và các hàm mất mát, vốn là cốt lõi của các phương

pháp học tương phản mà chúng ta sẽ thảo luận tiếp theo.

[TABLE_PLACEHOLDER: Bảng so sánh các thuộc tính cơ bản giữa Thị giác Máy tính và Phân tích Chuỗi thời gian. Các hàng bao gồm: Cấu trúc dữ liệu (Không gian 2D vs. Thời gian 1D), Quan hệ chính (Lân cận không gian vs. Phụ thuộc thời gian), Tính bất biến mong muốn (Xoay, Lật vs. Co giãn thời gian), Ví dụ Tăng cường dữ liệu.]

2.2.3 Mô hình cơ sở CA-TCC: Một quy trình bán giám sát đa giai đoạn nghiêm ngặt

Khuôn khổ CoFT là một sự mở rộng trực tiếp và có nguyên tắc của **CA-TCC (Tăng cường Tương phản - Phân cụm Tương phản Thời gian)** [7], một khuôn khổ tiên tiến cho phân loại chuỗi thời gian bán giám sát. Nó không chỉ đơn thuần là một hàm mất mát duy nhất mà là một quy trình hoàn chỉnh, đa giai đoạn được thiết kế để tận dụng tối đa cả dữ liệu không có nhãn và có nhãn. Việc hiểu rõ quy trình phức tạp này là rất quan trọng để đặt bối cảnh cho những đổi mới được trình bày trong luận văn này, vì nó tạo thành "sân chơi" nền tảng mà CoFT được xây dựng và đánh giá.



Hình 1: Học tương phản hai mục tiêu trong TS-TCC. Mô hình học cách bất biến với các phép tăng cường thông qua Tương phản Thời gian và nhạy cảm với cấu trúc thời gian thông qua Tương phản Ngữ cảnh.

2.3. Học Tương phản Tự giám sát (Self-Supervised Contrastive Learning)

Để giải quyết vấn đề khan hiếm nhãn, **Học Tương phản Tự giám sát** đã nổi lên như một trong những mô hình học biểu diễn mạnh mẽ nhất. Thay vì học từ các nhãn do con người cung cấp, nó tạo ra một **nhiệm vụ giám sát giả (pretext task)** từ chính dữ liệu.

Ý tưởng cốt lõi là học một không gian nhúng (embedding space) nơi các phiên bản

"biến thể" của cùng một mẫu dữ liệu (gọi là các **cặp dương - positive pairs**) được kéo lại gần nhau, trong khi các mẫu dữ liệu khác nhau (các **cặp âm - negative pairs**) bị đẩy ra xa. Điều này được thực hiện thông qua ba thành phần chính:

1. **Tăng cường Dữ liệu (Data Augmentation):** Đây là trái tim của học tương phản. Nó tạo ra các "khung nhìn" (views) khác nhau của cùng một chuỗi thời gian để hình thành các cặp dương. Như đã thảo luận ở mục 2.2.2, các phép tăng cường này phải được thiết kế cẩn thận để bảo toàn ngữ nghĩa thời gian. Một bài đánh giá hệ thống của Wen và cộng sự [9] đã chỉ ra rằng các phép tăng cường đơn giản như **jittering** (thêm nhiễu), **scaling** (thay đổi biên độ), và **cropping** (cắt xén) thường mang lại hiệu quả cao mà không cần đến sự phức tạp không cần thiết. Phát hiện này củng cố triết lý thiết kế của CoFT về việc ưu tiên sự đơn giản và hiệu quả.
2. **Bộ mã hóa (Encoder):** Một mạng nơ-ron (thường là sự kết hợp giữa CNN và Transformer) có nhiệm vụ ánh xạ chuỗi thời gian đầu vào thành một vector biểu diễn (embedding) trong không gian tiềm ẩn. Bộ mã hóa này là thành phần sẽ được chuyển giao cho các nhiệm vụ xuôi dòng (downstream tasks) sau khi được tiền huấn luyện.
3. **Hàm mất mát (Loss Function):** Động cơ toán học điều khiển việc "kéo-đẩy" các embedding. Hàm mất mát phổ biến và hiệu quả nhất trong lĩnh vực này là **NT-Xent**, sẽ được phân tích chi tiết dưới đây.

[FIGURE_PLACEHOLDER: Sơ đồ khối minh họa quy trình học tương phản. Bao gồm: (1) Mẫu đầu vào -> (2) Hai nhánh tăng cường dữ liệu (Aug 1, Aug 2) tạo ra hai khung nhìn -> (3) Cả hai khung nhìn đi qua cùng một Bộ mã hóa (Encoder) -> (4) Tạo ra hai vector biểu diễn -> (5) Hàm mất mát tương phản kéo các cặp dương lại gần và đẩy các cặp âm ra xa.]

2.3.1. Phân tích Hàm mất mát NT-Xent

Hàm mất mát **Cross-Entropy Chuẩn hóa theo Nhiệt độ (Normalized Temperature-scaled Cross-Entropy - NT-Xent)** [5] là nền tảng của nhiều khuôn khổ học tương phản thành công.

Công thức:

Cho một cặp dương (z_i, z_j) là các vector biểu diễn đã được mã hóa từ cùng một mẫu gốc, và một tập hợp gồm $2(N-1)$ mẫu âm khác trong một lô (batch), hàm mất mát cho mẫu i được định nghĩa là:

$$L_{i,j} = -\log \sum_{k=1, k \neq j}^{2N-1} \exp(\text{sim}(z_i, z_k) / \tau) \exp(\text{sim}(z_i, z_j) / \tau) \quad (\text{Phương trình 2.1})$$

Giải thích Trực quan:

Hãy tưởng tượng bạn có một mẫu neo z_i và một phiên bản biến thể của nó là z_j . Bạn trộn mẫu z_j này vào một tập hợp gồm $2N-2$ mẫu hoàn toàn khác. Nhiệm vụ của hàm mất mát là

giúp mô hình "nhận ra" z_j là đối tác chính xác của z_i từ trong cả tập hợp đó.

- **Tử số:** $\exp(\text{sim}(z_i, z_j)/\tau)$ đo lường sự tương đồng (thường là tương đồng cosine) giữa cặp dương. Mô hình được huấn luyện để **tối đa hóa** giá trị này, tức là làm cho hai vector này càng giống nhau càng tốt.
- **Mẫu số:** $\sum_{k=1, k \neq i}^N \exp(\text{sim}(z_i, z_k)/\tau)$ tính tổng sự tương đồng của z_i với **tất cả** các mẫu khác trong lô (bao gồm cả cặp dương z_j và tất cả các cặp âm). Đây là tổng của "bằng chứng" cho tất cả các lựa chọn có thể.
- **Tham số τ (Nhiệt độ - Temperature):** Một siêu tham số quan trọng. Nhiệt độ thấp ($\tau \rightarrow 0$) sẽ khuếch đại sự khác biệt về độ tương đồng, khiến mô hình phải làm việc chăm chỉ hơn để phân biệt giữa các cặp âm "khó" (những mẫu gần giống nhưng không phải là cặp dương). Điều này giúp mô hình học được các biểu diễn có tính phân biệt cao hơn.

Về bản chất, NT-Xent biến bài toán học biểu diễn thành một bài toán phân loại $2N-1$ lớp, trong đó mục tiêu là phân loại chính xác cặp dương từ tất cả các cặp âm.

2.4. Mô hình Nền tảng: Phân tích sâu về TS-TCC và CA-TCC

Khuôn khổ CoFT là một sự mở rộng có nguyên tắc của **CA-TCC**

(Contrastive-Augmented Time-Series Contrastive Clustering) [7], một ứng dụng tinh vi của các nguyên tắc học tương phản, được thiết kế đặc biệt cho kịch bản học bán giám sát trên chuỗi thời gian. Việc hiểu rõ CA-TCC là rất quan trọng vì nó tạo thành nền tảng mà CoFT xây dựng và cải tiến.

2.4.1. Tiền thân TS-TCC: Học Tương phản Mục tiêu kép

Tiền thân của CA-TCC là **TS-TCC (Time-Series representation learning via Temporal and Contextual Contrasting)** [6], một phương pháp tiên huấn luyện hoàn toàn tự giám sát. Sự đổi mới cốt lõi của nó là sử dụng một hàm mất mát mục tiêu kép để học các biểu diễn vừa mạnh mẽ (robust) trước các phép biến đổi, vừa nhạy cảm (sensitive) với cấu trúc thời gian.

1. **Tương phản Thời gian (Temporal Contrasting):** Mục tiêu này buộc mô hình phải **bất biến** với các phép tăng cường dữ liệu. Nó sử dụng hàm mất mát NT-Xent để kéo các biểu diễn của hai "khung nhìn" (được tạo bởi một phép tăng cường mạnh và một phép tăng cường yếu) của cùng một mẫu lại gần nhau.
2. **Tương phản Ngữ cảnh (Contextual Contrasting):** Mục tiêu này buộc mô hình phải học các **phụ thuộc thời gian**. Nó sử dụng một tác vụ dự đoán tự hồi quy (autoregressive prediction), trong đó mô hình phải dự đoán các biểu diễn trong tương lai của một khung nhìn dựa trên quá khứ của khung nhìn kia.

Sự kết hợp này đảm bảo rằng bộ mã hóa đã học không chỉ mạnh mẽ mà còn nắm bắt được các động lực thời gian quan trọng của tín hiệu.

2.4.2. Quy trình 4 Pha của CA-TCC

CA-TCC mở rộng TS-TCC thành một quy trình bán giám sát 4 pha hoàn chỉnh, được thiết kế để tận dụng tối đa cả dữ liệu có nhãn và không nhãn.

- **Pha 1: Tiền huấn luyện Tự giám sát:** Sử dụng TS-TCC để học các biểu diễn cơ sở từ toàn bộ dữ liệu không nhãn.
- **Pha 2: Tinh chỉnh có Giám sát:** Tinh chỉnh bộ mã hóa đã được tiền huấn luyện trên một lượng nhỏ dữ liệu có nhãn bằng hàm mất mát Cross-Entropy tiêu chuẩn.
- **Pha 3: Tạo Nhãn giả (Pseudo-labeling):** Sử dụng mô hình đã tinh chỉnh để gán nhãn cho dữ liệu không nhãn. Các dự đoán có độ tin cậy cao (ví dụ: xác suất softmax > 0.95) được giữ lại.
- **Pha 4: Tinh chỉnh bằng Học Tương phản có Giám sát:** Đây là bước đổi mới cốt lõi. Thay vì NT-Xent, pha này sử dụng **Hàm mất mát Tương phản có Giám sát (Supervised Contrastive Loss - LSupCon)** để tinh chỉnh lại bộ mã hóa trên tập dữ liệu kết hợp (nhãn gốc và nhãn giả).

2.4.3. Phân tích Hàm mất mát Tương phản có Giám sát (LSupCon)

LSupCon [43] là một phiên bản mạnh mẽ hơn của LNT-Xent vì nó tận dụng thông tin nhãn có sẵn (cả nhãn thật và nhãn giả).

Công thức:

Đối với một mẫu neo i , mất mát SupCon được định nghĩa là:

$$LSupCon(i) = -\mathbb{E}_{p \in P(i)} \log \sum_{k \in A(i)} \exp(\text{sim}(z_i, z_k) / \tau) \exp(\text{sim}(z_i, z_p) / \tau)$$
 (Phương trình 2.2)

Sự khác biệt chính so với NT-Xent:

Trong LNT-Xent, tập hợp các cặp dương $P(i)$ cho một mẫu neo i chỉ chứa một phần tử (khung nhìn tăng cường còn lại của chính nó).

Trong LSupCon, tập hợp các cặp dương $P(i)$ cho một mẫu neo i chứa **tất cả các mẫu khác trong lô có cùng nhãn lớp với mẫu i** .

Mục tiêu:

Thay vì chỉ kéo hai khung nhìn của một mẫu lại gần nhau, LSupCon kéo toàn bộ cụm các mẫu của cùng một lớp lại gần nhau trong không gian tiềm ẩn, đồng thời đẩy chúng ra xa các cụm của các lớp khác. Điều này tạo ra một không gian đặc trưng có tính phân biệt cao hơn nhiều, giúp bộ phân loại tuyến tính ở giai đoạn cuối hoạt động hiệu quả hơn.

2.5. Hướng tới CoFT: Lý do cho Đồng huấn luyện Đa miền

Mặc dù CA-TCC là một khuôn khổ cực kỳ mạnh mẽ, nó vẫn hoạt động trên một miền duy nhất: **miền thời gian**. Điều này đặt ra một câu hỏi tự nhiên và là tiền đề cho luận văn này: *Liệu chúng ta có thể học được các biểu diễn tốt hơn nữa bằng*

cách tận dụng một góc nhìn bổ sung, có tính hiệp đồng về dữ liệu không?

Các phương pháp hợp nhất đa miền truyền thống, chẳng hạn như hợp nhất sớm (nổi đặc trưng) hoặc hợp nhất muộn (tổ hợp dự đoán), có những hạn chế cố hữu. CoFT đề xuất một giải pháp tinh vi hơn dựa trên lý thuyết **đồng huấn luyện (co-training)** [3]. Ý tưởng cốt lõi là coi miền thời gian và **miền tần số** là hai "khung nhìn" (views) độc lập có điều kiện về dữ liệu. Thay vì chỉ hợp nhất, chúng ta có thể để chúng "dạy" lẫn nhau. Điều này tạo ra một vòng lặp phản hồi cộng sinh, trong đó mỗi miền giúp điều chuẩn và cải thiện biểu diễn của miền kia, một cơ chế được kỳ vọng sẽ đặc biệt hiệu quả trong các môi trường khan hiếm nhãn.

Lý thuyết và kiến trúc cụ thể của phương pháp đồng huấn luyện này sẽ là trọng tâm của Chương 3.

3 TRIỂN KHAI VÀ PHƯƠNG PHÁP LUẬN

Chương này trình bày một cách toàn diện về khuôn khổ **CoFT (Co-training with Frequency and Temporal domains)**, không chỉ chi tiết hóa kiến trúc cuối cùng mà còn ghi lại hành trình nghiên cứu, bao gồm các quyết định thiết kế, những thử nghiệm thất bại và các khám phá phản trực giác đã định hình nên sự phát triển của nó.

3.1 Công nghệ và Môi trường thực nghiệm

3.1.1 Cấu hình Phần cứng và Phần mềm

Nghiên cứu được thực hiện trên một hệ thống phần cứng và phần mềm được lựa chọn cẩn thận để cân bằng giữa việc phát triển nhanh và xác thực hiệu suất trên quy mô lớn.

Cấu hình Phần cứng:

- **Phát triển:** Một máy tính trang bị GPU NVIDIA RTX 4060 (8GB) được sử dụng cho việc phát triển ban đầu và tối ưu hóa trong điều kiện bộ nhớ hạn chế.
- **Tính toán Song song:** Một máy chủ Linux do tổ chức nghiên cứu cung cấp, trang bị 3 GPU NVIDIA RTX 5000, được sử dụng để chạy song song nhiều thử nghiệm trong giai đoạn tối ưu hóa ban đầu.
- **Xác thực:** Một máy chủ Colab Pro với GPU NVIDIA A100 (40GB) được sử dụng cho các cuộc tìm kiếm siêu tham số quy mô lớn và xác thực hiệu suất cuối

cùng.

Hệ sinh thái Phần mềm:

Toàn bộ dự án được xây dựng dựa trên một hệ sinh thái phần mềm đa dạng, được phân loại như sau để làm rõ vai trò của từng thành phần:

- **Nền tảng Học sâu (Deep Learning Core):**
 - **PyTorch (v2.2.2+):** Framework chính cho việc xây dựng, huấn luyện và xác thực các mô hình học sâu. Bao gồm torchvision và torchaudio cho các tác vụ liên quan.
 - **CUDA (v12.1):** Nền tảng tính toán song song của NVIDIA, cần thiết để tăng tốc các hoạt động trên GPU.
- **Ngăn xếp Khoa học Dữ liệu (Data Science Stack):**
 - **NumPy:** Thư viện nền tảng cho các phép toán số học hiệu năng cao trên mảng đa chiều.
 - **Pandas & openpyxl:** Được sử dụng để xử lý, thao tác và phân tích dữ liệu có cấu trúc, đặc biệt là từ các tệp CSV và Excel.
 - **Scikit-learn:** Cung cấp các công cụ hiệu quả cho việc phân chia dữ liệu, các độ đo đánh giá (F1-score, accuracy) và các mô hình học máy truyền thống.
 - **MNE (v0.20.7):** Một thư viện chuyên dụng cho việc xử lý và phân tích dữ liệu sinh lý thần kinh (neurophysiological), đặc biệt quan trọng cho các bộ dữ liệu EEG như Sleep-EDF và Epilepsy.
 - **mat4py:** Dùng để tải dữ liệu từ định dạng tệp .mat của MATLAB.
- **Tăng cường và Biến đổi Dữ liệu (Augmentation & Transformation):**
 - **tsaug:** Thư viện chuyên dụng cho việc tăng cường dữ liệu chuỗi thời gian, cung cấp các phép biến đổi như jitter, scale, crop.
 - **einops:** Cung cấp một API mạnh mẽ và linh hoạt để thao tác với các tensor, giúp mã nguồn trở nên dễ đọc và hiệu quả hơn.
- **Môi trường Thử nghiệm và Tự động hóa (Experimentation & Automation):**
 - **Jupyter Notebook & Google Colab:** Môi trường phát triển tương tác chính. Được sử dụng để khám phá dữ liệu, gỡ lỗi, trực quan hóa kết quả và thực thi các quy trình tìm kiếm siêu tham số quy mô lớn (CoFT_Parameter_GridSearch_Colab.ipynb).
 - **Bash Scripts (search.sh):** Các script dòng lệnh được sử dụng để tự động hóa toàn bộ quy trình tìm kiếm siêu tham số. Chúng tận dụng các công cụ hệ thống như sed, grep, bc, và tee để tự động sửa đổi tệp cấu hình, chạy thí nghiệm và trích xuất kết quả một cách có hệ thống.
 - **argparse:** Thư viện Python để phân tích các đối số dòng lệnh, cho phép điều khiển linh hoạt các chế độ hoạt động của mô hình (main.py).

3.1.2 Các Nguyên tắc Chỉ đạo cho Khả năng Tái lập

Linh hồn của chương này là **khả năng tái lập**. Mọi lựa chọn thiết kế, tham số và quy trình đều được ghi lại với mục đích rằng một nhà nghiên cứu khác có thể đạt được kết quả giống hệt 100%. Cam kết này được duy trì thông qua các chiến lược sau:

1. **Phân chia Dữ liệu Nhất quán:** Tất cả các thí nghiệm, bao gồm mô hình cơ sở và mô hình đề xuất, đều được tiến hành trên cùng một tập huấn luyện, xác thực và kiểm tra để đảm bảo so sánh công bằng.
2. **Hạt giống Ngẫu nhiên Cố định:** Tất cả các quy trình ngẫu nhiên, từ khởi tạo trọng số đến xáo trộn dữ liệu, đều được kiểm soát bằng một tập hợp 5 hạt giống ngẫu nhiên cố định (0, 1, 2, 3, 4). Kết quả được báo cáo dưới dạng trung bình và độ lệch chuẩn qua các lần chạy độc lập này.
3. **Biến có thể Kiểm soát:** Khi so sánh CoFT với mô hình cơ sở, biến *duy nhất* được thay đổi là cờ tính năng `--enable_coft`. Thiết kế này đảm bảo rằng mã và hành vi của mô hình cơ sở vẫn hoàn toàn không bị thay đổi.
4. **Mã nguồn Mở:** Toàn bộ dự án được xây dựng bằng các thư viện công khai và sẽ được phát hành để đảm bảo cộng đồng có thể kiểm tra, xác thực và xây dựng dựa trên công trình này.

3.2 Các bộ dữ liệu Benchmark

Để đảm bảo một sự so sánh **ngghiêm ngặt và công bằng về mặt khoa học**, một quyết định phương pháp luận quan trọng đã được đưa ra là tiến hành tất cả các thí nghiệm trên **cùng một bộ dữ liệu benchmark** được sử dụng trong công bố CA-TCC gốc [7]. Bằng cách kế thừa bộ benchmark đã được thiết lập này, chúng tôi có thể cô lập trực tiếp tác động hiệu suất của kiến trúc đồng huấn luyện hai miền được đề xuất.

- **Nhận dạng Hoạt động của Con người (HAR):** Dữ liệu chuỗi thời gian 9 kênh từ cảm biến điện thoại thông minh, đại diện cho một bài toán đa lớp cân bằng với các mẫu động rõ ràng.
- **Sleep-EDF (Phân loại Giai đoạn Giấc ngủ):** Dữ liệu EEG một kênh, chuỗi dài, đại diện cho một bài toán y tế với sự mất cân bằng lớp nghiêm trọng và các mẫu tinh tế.
- **Epilepsy (Phát hiện Co giật):** Dữ liệu EEG một kênh, chuỗi ngắn, đại diện cho một bài toán phân loại nhị phân, mất cân bằng cao.

3.2.1 Phương pháp Phân chia Dữ liệu Bán giám sát

Nền tảng của nghiên cứu này là việc mô phỏng sự khan hiếm nhãn. Đối với mỗi bộ dữ liệu, dữ liệu huấn luyện chính thức, `D_train_full`, phải chịu một **quy trình phân chia phân tầng**. Điều này đảm bảo rằng ngay cả với một tỷ lệ nhỏ nhãn, sự phân

phối lớp của bộ dữ liệu gốc vẫn được bảo tồn, ngăn ngừa sai lệch lấy mẫu và đảm bảo việc đánh giá là công bằng và có thể tái lập.

3.2.2 Tiền xử lý và Chuẩn bị Dữ liệu

Mỗi bộ dữ liệu benchmark đòi hỏi một quy trình tiền xử lý riêng biệt để chuyển đổi dữ liệu thô thành định dạng tensor phù hợp cho việc huấn luyện. Các bước này là rất quan trọng để đảm bảo khả năng tái lập và hiệu suất của mô hình.

Nhận dạng Hoạt động của Con người (HAR):

- **Tải dữ liệu:** Dữ liệu được tải trực tiếp từ các tệp văn bản (.txt) trong bộ dữ liệu gốc. Chín kênh tín hiệu—bao gồm gia tốc kế toàn phần (total acceleration), gia tốc kế cơ thể (body acceleration), và con quay hồi chuyển (gyroscope)—được đọc riêng lẻ.
- **Xếp chồng Kênh:** Chín kênh riêng lẻ sau đó được xếp chồng (stacked) để tạo thành một tensor đa biến duy nhất có kích thước (số mẫu, 9, 128).
- **Chuẩn hóa Nhãn:** Các nhãn được đọc và điều chỉnh để bắt đầu từ 0 (thay vì 1) bằng cách trừ đi giá trị tối thiểu.
- **Phân chia Dữ liệu:** Tập huấn luyện gốc được chia thành tập huấn luyện mới và tập xác thực theo tỷ lệ 80/20.
- **Lưu trữ:** Các tập dữ liệu cuối cùng (huấn luyện, xác thực, kiểm tra) được lưu dưới dạng tệp .pt của PyTorch. Đáng chú ý, không có bước chuẩn hóa giá trị tín hiệu (như Z-score) nào được áp dụng ở giai đoạn này.

Sleep-EDF (Phân loại Giai đoạn Giấc ngủ):

- **Tải dữ liệu:** Thư viện mne được sử dụng để đọc các tệp .edf (European Data Format). Kênh tín hiệu EEG Fpz-Cz được chọn lọc cho việc phân tích.
- **Phân đoạn (Segmentation):** Tín hiệu EEG liên tục được phân đoạn thành các cửa sổ (epochs) không chồng chéo, mỗi cửa sổ dài 30 giây, tương ứng với tiêu chuẩn chấm điểm giấc ngủ.
- **Gán nhãn:** Các chú thích từ tệp Hypnogram được ánh xạ sang các nhãn số (0-5). Các giai đoạn "Sleep stage 4" được gộp vào "Sleep stage 3". Các giai đoạn không xác định hoặc có chuyển động được đánh dấu là "UNKNOWN".
- **Lọc dữ liệu:** Để tập trung vào các giai đoạn ngủ chính, một thuật toán được áp dụng để loại bỏ 30 phút dữ liệu ở trạng thái "Thức" (Wake) ở đầu và cuối mỗi bản ghi.
- **Lưu trữ:** Dữ liệu đã xử lý của mỗi đối tượng được lưu dưới dạng tệp .npz, chứa các chuỗi tín hiệu và nhãn tương ứng.

Epilepsy (Phát hiện Co giật):

- **Tải dữ liệu:** Dữ liệu được đọc từ một tệp .csv duy nhất. Cột cuối cùng được coi là nhãn, và các cột còn lại là các điểm dữ liệu của chuỗi thời gian.

- **Chuẩn hóa Tín hiệu:** MinMaxScaler của Scikit-learn được áp dụng trên toàn bộ dữ liệu tín hiệu để co các giá trị về khoảng $[0, 1]$. Đây là bước chuẩn hóa quan trọng nhất cho bộ dữ liệu này.
- **Chuẩn hóa Nhãn (Tạo bài toán nhị phân):** Bộ dữ liệu gốc có 5 lớp. Lớp 1 (biểu thị cơn co giật) được giữ nguyên, trong khi tất cả các lớp khác (2 đến 5) được gộp lại thành một lớp duy nhất 0 (không co giật). Điều này chuyển đổi bài toán đa lớp thành một bài toán phân loại nhị phân.
- **Phân chia Dữ liệu:** Dữ liệu sau đó được chia thành các tập huấn luyện, xác thực và kiểm tra theo tỷ lệ 64/16/20.
- **Lưu trữ:** Dữ liệu được định hình lại (thêm một chiều kênh) và lưu dưới dạng các tệp .pt của PyTorch.

3.3 Phương pháp luận Kiểm thử và Các độ đo Đánh giá

- **Chiến lược So sánh Công bằng:**
 - **Cơ sở được tinh chỉnh:** Mô hình cơ sở CA-TCC được tối ưu hóa siêu tham số một cách nghiêm ngặt để đảm bảo nó hoạt động ở hiệu suất cao nhất, tạo ra một phép so sánh thực sự thách thức.
 - **Nghiên cứu Cắt lớp (Ablation Study):** Các thí nghiệm được thiết kế để phân tích từng thành phần của CoFT, cô lập đóng góp của kiến trúc hai nhánh, cơ chế đồng huấn luyện và phương pháp tổ hợp.
- **Các độ đo Đánh giá:**
 - **Độ chính xác (Accuracy):** Tỷ lệ các dự đoán đúng trên tổng số mẫu.
 - **Điểm F1 Vĩ mô (Macro F1-Score):** Trung bình của điểm F1 trên từng lớp, đặc biệt quan trọng đối với các bộ dữ liệu mất cân bằng như Sleep-EDF và Epilepsy.
 - **Kiểm định Thống kê:** Kiểm định t-test cặp được sử dụng để xác định xem sự cải thiện hiệu suất của CoFT so với mô hình cơ sở có ý nghĩa thống kê hay không.

3.4 Quy trình Triển khai: Từ Nền tảng đến Đổi mới

Phần này sẽ trình bày chi tiết hành trình xây dựng CoFT, bắt đầu bằng việc phân tích sâu về kiến trúc nền tảng (cũ) và sau đó giới thiệu các cải tiến của kiến trúc mới.

3.4.1 Mô hình Nền tảng: Phân tích sâu về CA-TCC

Khuôn khổ CoFT là một sự mở rộng trực tiếp và có nguyên tắc của **CA-TCC**, một quy trình tiên tiến cho phân loại chuỗi thời gian bán giám sát. Việc hiểu rõ quy trình phức tạp này là rất quan trọng, vì nó tạo thành nền tảng vững chắc mà CoFT xây dựng và cải tiến.


Kiến trúc Bộ mã hóa (Encoder):

Bộ mã hóa của CA-TCC là một kiến trúc mạnh mẽ kết hợp các Mạng Nơ-ron Tích chập (CNN) và Transformer để trích xuất đặc trưng.

- **Các khối Tích chập 1D:** Mô hình sử dụng 3 khối Conv1D với số kênh lần lượt là [32, 64, 128] và kích thước kernel là [8, 5, 3]. Các khối này có nhiệm vụ trích xuất các mẫu cục bộ, bất biến theo thời gian trong tín hiệu.
- **Cơ chế Chú ý (Attention):** Sau các khối tích chập, một khối Transformer với cơ chế tự chú ý đa đầu (4 đầu) được sử dụng để mô hình hóa các phụ thuộc thời gian ở khoảng cách xa.
- **Chuẩn hóa và Điều chuẩn:** Chuẩn hóa theo lô (Batch Normalization) được áp dụng sau mỗi lớp tích chập để ổn định quá trình huấn luyện. Dropout (0.3) và cắt gradient (gradient clipping) được sử dụng để chống lại việc học vẹt.

Quy trình Huấn luyện 4 Pha:

Theo bài báo gốc [7], CA-TCC không phải là một mô hình đơn lẻ, mà là một quy trình bán giám sát gồm 4 pha được thiết kế để tận dụng tối đa cả dữ liệu không nhãn và có nhãn.



3.1: Quy trình 4 pha cho huấn luyện bán giám sát của CA-TCC. Pha 1, TS-TCC được huấn luyện với dữ liệu hoàn toàn không nhãn. Tiếp theo, chúng ta sử dụng một vài mẫu có nhãn để tinh chỉnh bộ mã hóa đã được tiền huấn luyện trong Pha 2. Sau đó, trong Pha 3, chúng ta tạo ra các nhãn giả cho dữ liệu không nhãn. Cuối cùng, Pha 4 bao gồm việc triển khai dữ liệu được gán nhãn giả trong quá trình huấn luyện bán giám sát. (ảnh được điều chỉnh từ Eldele et al., 2023 [7])

1. **Pha 1: Tiền huấn luyện Tự giám sát (Self-supervised Pretraining):** Bộ mã hóa được huấn luyện trên toàn bộ dữ liệu *không nhãn* bằng cách sử dụng khuôn khổ TS-TCC. Giai đoạn này học các biểu diễn chung, mạnh mẽ thông qua hàm mất mát tương phản mục tiêu kép (Tương phản Thời gian và Tương phản Ngữ cảnh) như đã mô tả trong Chương 2.
2. **Pha 2: Tinh chỉnh (Fine-tuning):** Bộ mã hóa đã được tiền huấn luyện từ Pha 1

được tinh chỉnh bằng cách sử dụng một lượng nhỏ dữ liệu có *nhãn* (D_L). Một bộ phân loại tuyến tính được thêm vào và toàn bộ mô hình được huấn luyện bằng hàm mất mát Cross-Entropy tiêu chuẩn.

- 3. **Pha 3: Tạo Nhãn giả (Generating Pseudo-labels):** Mô hình đã được tinh chỉnh từ Pha 2 được sử dụng để đưa ra dự đoán trên toàn bộ tập dữ liệu *không nhãn* (D_U). Các dự đoán có độ tin cậy cao (ví dụ: xác suất softmax > 0.95) được giữ lại làm nhãn giả, tạo ra một tập dữ liệu được gán nhãn mở rộng.
- 4. **Pha 4: Huấn luyện Bán giám sát (Semi-supervised Training):** Đây là pha cốt lõi của CA-TCC. Mô hình được huấn luyện lại trên tập dữ liệu kết hợp (nhãn gốc và nhãn giả). Sự đổi mới chính ở đây là việc thay thế hàm mất mát tương phản ngẫu nhiên không giám sát bằng **Hàm mất mát Tương phản có Giám sát (Supervised Contrastive Loss - L_{SCC})**. Hàm mất mát này tận dụng thông tin từ các nhãn (cả thật và giả) để kéo tất cả các mẫu của cùng một lớp lại gần nhau trong không gian tiềm ẩn, tạo ra các cụm lớp chặt chẽ và tách biệt rõ ràng hơn.

Quy trình 4 pha hoàn chỉnh này đại diện cho mô hình cơ sở phức tạp mà CoFT xây dựng dựa trên đó. Bằng cách bảo tồn quy trình này cho nhánh thời gian của mình, luận văn này có thể cô lập và đánh giá một cách nghiêm ngặt những lợi ích đạt được bằng cách giới thiệu nhánh tần số song song và cơ chế đồng huấn luyện chéo miền.

3.4.2 Kiến trúc Mới: Khuôn khổ CoFT và Quy trình 6 Bước

Trong quá trình phát triển CoFT, chúng tôi đã mở rộng quy trình 4 pha của CA-TCC thành một pipeline **6 bước** chi tiết hơn. Mục đích của việc mở rộng này là để **đo lường và chẩn đoán** chất lượng của các biểu diễn (representations) mà mô hình học được ở từng giai đoạn quan trọng. Hai bước được thêm vào là các bước **đánh giá (evaluation)**, không phải các bước huấn luyện mô hình chính.

Bảng 3.1: Ánh xạ từ Quy trình CA-TCC sang Quy trình 6 bước của CoFT

Quy trình CoFT (trong Code & Luận văn)	Tương ứng với Pha của CA-TCC	Mục đích
Stage 1: self_supervised	Pha 1	Huấn luyện tương phản để học biểu diễn ban đầu.
Stage 2: train_linear_{p}	(Bước đánh giá #1)	ĐÁNH GIÁ: Đóng băng bộ mã hóa và huấn luyện một lớp tuyến tính để xem biểu diễn học được ở Stage 1 tốt đến mức nào.

Stage 3: $ft_{\{p\}}$	Pha 2	Tinh chỉnh bộ mã hóa với một ít dữ liệu có nhãn.
Stage 4: gen_pseudo_labels	Pha 3	Tạo nhãn giả từ mô hình đã tinh chỉnh.
Stage 5: SupCon	Pha 4	Huấn luyện lại với cả nhãn thật và nhãn giả bằng Supervised Contrastive Loss.
Stage 6: $train_linear_SupCon_{\{p\}}$	(Bước đánh giá #2)	ĐÁNH GIÁ: Đóng băng bộ mã hóa một lần nữa sau khi đã qua SupCon, và huấn luyện một lớp tuyến tính khác để đo lường sự cải thiện về chất lượng biểu diễn so với Stage 2.


Tại sao lại cần 6 bước?

Việc chia nhỏ quy trình thành 6 bước mang lại hai lợi ích chính:

1. **Ổn định khi Huấn luyện (Training Stability):** Các thử nghiệm ban đầu cho thấy việc huấn luyện end-to-end (tất cả trong một) rất dễ gặp lỗi. Việc tách thành các giai đoạn giúp mô hình học các biểu diễn ổn định ở từng bước trước khi chuyển sang các tác vụ phức tạp hơn.
2. **Đánh giá Khoa học (Rigorous Evaluation):** Các bước $train_linear$ (Stage 2 và 6) cho phép chúng tôi định lượng được sự cải thiện. Ví dụ, chúng tôi có thể so sánh trực tiếp độ chính xác của Stage 2 và Stage 6 để chứng minh rằng pha SupCon (Stage 5) thực sự đã cải thiện chất lượng của các biểu diễn. Điều này là nền tảng cho các phân tích trong Chương 4.

3.4.3 Kiến trúc Hai nhánh của CoFT

CoFT triển khai một kiến trúc hai nhánh song song, một cho miền thời gian và một cho miền tần số. Thiết kế này được xây dựng một cách có chủ ý để tạo ra một thí nghiệm có kiểm soát.



Hình 3.2: Tổng quan cấp cao về khuôn khổ CoFT. Nó cho thấy các nhánh Thời gian và Tần số song song, và mô-đun đồng huấn luyện trung tâm điều phối việc chuyển giao kiến thức trước khi đưa ra một dự đoán tổ hợp cuối cùng.

- **Nhánh Thời gian (Temporal Branch):** Nhánh này bảo tồn **chính xác** kiến trúc bộ mã hóa của CA-TCC (đã mô tả trong mục 3.4.1). Quyết định này là rất quan trọng để đảm bảo một sự so sánh công bằng, cho phép chúng tôi cô lập hoàn toàn lợi ích do việc bổ sung nhánh tần số mang lại.
- **Nhánh Tần số (Frequency Branch):**
 - **Sự tương đương về Kiến trúc (Architectural Parity):** Một quyết định phương pháp luận quan trọng là làm cho kiến trúc của nhánh tần số **giống**

hệ với nhánh thời gian. Điều này đảm bảo rằng bất kỳ lợi ích hiệu suất nào quan sát được đều đến từ chính thông tin trong miền tần số, chứ không phải từ lợi thế về kiến trúc của một nhánh so với nhánh kia.

- **Biến đổi Miền Tần số:** Để xử lý tín hiệu trong miền tần số, một quy trình biến đổi đã được áp dụng:
 1. **Biến đổi Fourier Nhanh cho Tín hiệu Thực (RFFT):** Chúng tôi sử dụng `torch.fft.rfft` để biến đổi tín hiệu đầu vào. RFFT hiệu quả hơn về mặt tính toán và bộ nhớ so với FFT tiêu chuẩn cho các tín hiệu đầu vào có giá trị thực.
 2. **Phân tách Biên độ-Pha:** Đầu ra phức của RFFT được phân tách thành hai thành phần có giá trị thực: biên độ (`torch.abs`) và pha (`torch.angle`). Việc này bảo toàn toàn bộ thông tin quang phổ.
 3. **Xếp chồng Kênh:** Các tensor biên độ và pha được xếp chồng lên nhau dọc theo chiều kênh (`torch.cat`). Điều này tạo ra một tensor có giá trị thực với số kênh gấp đôi, tương thích hoàn toàn với các lớp Conv1D tiêu chuẩn của bộ mã hóa.
- **Thích ứng Kiến trúc Động:** Để xử lý các độ dài chuỗi thời gian khác nhau giữa các bộ dữ liệu, lớp phân loại cuối cùng của nhánh tần số được khởi tạo một cách động trong lần truyền thuận đầu tiên, đảm bảo tính linh hoạt và mạnh mẽ của kiến trúc.

3.4.4 Tăng cường Dữ liệu cho Hai Miền

CoFT sử dụng một tập hợp các phép tăng cường dữ liệu hiệu quả và tiết kiệm chi phí tính toán, tuân theo triết lý "đơn giản hơn là phức tạp" đã được xác thực trong các thí nghiệm của chúng tôi (xem Chương 4).

- **Miền Thời gian:** Áp dụng các phép tăng cường đã được chứng minh hiệu quả từ CA-TCC: **Jittering** (thêm nhiễu), **Scaling** (thay đổi biên độ), và **Cropping** (cắt xén).
- **Miền Tần số:** Sử dụng một cách tiếp cận thận trọng để tránh làm hỏng các mẫu chẩn đoán, được thiết kế để bắt chước các nhiễu tín hiệu thực tế:
 - **Thêm nhiễu trong miền FFT:** Thêm nhiễu Gaussian có biên độ thấp trực tiếp vào phổ tần số.
 - **Che Tần số Chọn lọc (Frequency Masking):** Che ngẫu nhiên các dải tần số hẹp để mô phỏng các bộ lọc hoặc nhiễu trong thế giới thực.

3.4.5 Hàm mất mát Hỗn hợp và Cơ chế Đồng huấn luyện

Việc điều phối học tập hai nhánh được chi phối bởi một hàm mất mát hỗn hợp phức tạp.

Công thức:

Tổng mất mát, L_{total} , được xây dựng dưới dạng tổng có trọng số của bốn thành phần

riêng biệt:

$$L_{total} = (L_{sup_t} + L_{sup_f}) + \lambda_{ct} \cdot L_{cotraining} + \lambda_{cs} \cdot L_{consistency} \text{ (Phương trình 3.1)}$$

- L_{sup_t} & L_{sup_f} : Mất mát phân loại có giám sát (Cross-Entropy) cho nhánh thời gian và tần số, được tính toán trên các nhãn thực tế.
- $L_{cotraining}$: Mất mát đồng huấn luyện. Đây là cốt lõi của cơ chế dạy học tương hỗ, trong đó một nhánh được huấn luyện trên các *nhãn giả* có độ tin cậy cao được tạo ra bởi nhánh kia.
- $L_{consistency}$: Một mất mát nhất quán đặc trưng (ví dụ: Lỗi Bình phương Trung bình) khuyến khích các vector nhúng cấp cao từ cả hai nhánh tương tự nhau cho cùng một mẫu đầu vào.
- λ_{ct} (Trọng số đồng huấn luyện): Một siêu tham số điều chỉnh ảnh hưởng của mất mát đồng huấn luyện. Một khám phá quan trọng của công trình này (chi tiết trong Chương 4) là giá trị cực thấp của tham số này là tối ưu.
- λ_{cs} (Trọng số nhất quán): Một siêu tham số kiểm soát sức mạnh của việc điều chuẩn nhất quán đặc trưng.


Hàm mất mát này cân bằng bốn mục tiêu: buộc mỗi nhánh phải học từ sự thật (L_{sup}), học từ "quan điểm" của nhánh kia ($L_{cotraining}$), và phát triển một "sự hiểu biết" chung về dữ liệu ($L_{consistency}$).

3.5 Khuôn khổ CoFT: Kiến trúc và Quy trình

3.5.1 Kiến trúc hai nhánh: Thiết kế và Triển khai

CoFT sử dụng một kiến trúc hai nhánh song song. Thiết kế ban đầu, được trình bày chi tiết dưới đây, được xây dựng cẩn thận để duy trì sự đối xứng về kiến trúc. Quyết định này là một phần quan trọng trong phương pháp luận khoa học của chúng tôi, cho phép so sánh công bằng và có kiểm soát giữa miền thời gian và tần số.


Nhánh thời gian bảo tồn chính xác kiến trúc CA-TCC để đảm bảo so sánh công bằng. Đối với **nhánh tần số**, quyết định phản chiếu kiến trúc thời gian là một lựa chọn phương pháp luận có chủ ý để thiết lập một đường cơ sở có kiểm soát. Bằng cách giữ cho dung lượng mô hình giống hệt nhau, chúng tôi có thể đảm bảo rằng bất kỳ sự khác biệt hiệu suất nào quan sát được đều hoàn toàn do các đặc điểm vốn có của chính dữ liệu miền tần số, chứ không phải do lợi thế về kiến trúc.



Hình 3: Kiến trúc của khối Transformer được sử dụng trong cả bộ mã hóa thời gian

và tần số. Các đặc trưng của bộ mã hóa được chiếu và kết hợp với một token phân loại, được xử lý thông qua các lớp chú ý đa đầu và MLP, và cuối cùng được sử dụng cho các nhiệm vụ xuôi dòng.

3.5.3 Chiến lược Tăng cường Dữ liệu cho miền tần số



Hình 4: Cơ chế Tương phản Tần số. Tương tự như nhánh thời gian, nhánh tần số sử dụng các phép tăng cường (Nhiều Quang phổ, Che Tần số) và một bộ mã hóa dựa trên Transformer để học các biểu diễn mạnh mẽ thông qua một mất mát tương phản.

Tăng cường dữ liệu (Data Augmentation) là một thành phần cốt lõi trong các khuôn khổ học tương phản, có nhiệm vụ tạo ra các "khung nhìn" (views) khác nhau của cùng một mẫu dữ liệu để hình thành các cặp dương. CoFT sử dụng một tập hợp các phép tăng cường hiệu quả và tiết kiệm chi phí tính toán, tuân theo triết lý "đơn giản hơn là phức tạp". Các chiến lược này được thiết kế riêng cho từng miền để bảo toàn các đặc tính quan trọng của tín hiệu.

- **Miền Thời gian:** Áp dụng các phép tăng cường đã được chứng minh hiệu quả từ các công trình trước đó như TS-TCC và CA-TCC:
 - **Jittering:** Thêm nhiễu Gaussian có độ lệch chuẩn nhỏ vào mỗi điểm dữ liệu của chuỗi thời gian. Phép biến đổi này giúp mô hình trở nên mạnh mẽ hơn trước các nhiễu cảm biến nhỏ.
 - **Scaling:** Nhân toàn bộ chuỗi thời gian với một hệ số ngẫu nhiên được lấy từ một phân phối chuẩn. Điều này giúp mô hình bất biến với các thay đổi về biên độ tổng thể của tín hiệu.
 - **Cropping:** Cắt ngẫu nhiên một đoạn con từ chuỗi thời gian gốc. Đây là một trong những phương pháp tăng cường hiệu quả nhất, buộc mô hình phải học các đặc trưng cục bộ và bất biến theo vị trí.
- **Miền Tần số:** Việc tăng cường dữ liệu trong miền tần số đòi hỏi một cách tiếp cận thận trọng hơn để tránh làm hỏng các mẫu quang phổ quan trọng, đặc biệt là với các tín hiệu y tế. Các phương pháp được thiết kế để bắt chước các nhiễu tín hiệu trong thực tế:
 - **Thêm nhiễu Quang phổ (Spectral Noise):** Thêm nhiễu Gaussian có biên độ thấp trực tiếp vào phổ tần số (cả thành phần biên độ và pha) sau khi thực hiện biến đổi FFT.
 - **Che Tần số (Frequency Masking):** Che ngẫu nhiên (đặt giá trị về 0) các dải tần số hẹp. Kỹ thuật này tương tự như [SpecAugment](#) trong xử lý giọng nói, giúp mô hình trở nên mạnh mẽ hơn trước sự mất mát thông tin trong một vài dải tần cụ thể, mô phỏng các bộ lọc hoặc nhiễu băng hẹp trong thế giới thực.

Chương 4: KẾT QUẢ VÀ PHÂN TÍCH

Chương này trình bày chi tiết các kết quả thực nghiệm của nghiên cứu, được cấu trúc một cách có hệ thống để trả lời từng câu hỏi nghiên cứu đã được đặt ra trong Chương 1. Mục tiêu của chương không chỉ là trình bày các chỉ số hiệu suất cuối cùng, mà còn là ghi lại một cách minh bạch **hành trình nghiên cứu** — từ việc xác thực hiệu suất của mô hình được đề xuất, phân tích sâu các nguồn gốc của sự cải thiện, cho đến việc khám phá các nguyên tắc cơ bản chi phối sự tương tác giữa các miền và khả năng chuyển giao các nguyên tắc đó. Mỗi tiểu mục sẽ tương ứng với một câu hỏi nghiên cứu, cung cấp các bằng chứng thực nghiệm, diễn giải, và phân tích để đưa ra một câu trả lời toàn diện và thuyết phục.

4.1 Trả lời Câu hỏi Nghiên cứu 1: CoFT có thể vượt trội hơn một mô hình cơ sở tiên tiến không?

Câu hỏi nghiên cứu đầu tiên và cũng là cốt lõi nhất tìm cách xác định liệu kiến trúc đồng huấn luyện hai miền được đề xuất, **CoFT**, có khả năng vượt trội một cách đáng kể và nhất quán so với một mô hình cơ sở đơn miền, tiên tiến (state-of-the-art) là **CA-TCC** hay không. Để trả lời câu hỏi này, chúng tôi đã tiến hành một loạt các thí nghiệm so sánh trực tiếp trên ba bộ dữ liệu benchmark (HAR, Sleep-EDF, và Epilepsy) dưới hai kịch bản khan hiếm nhãn điển hình (1% và 5% dữ liệu có nhãn).

Các kết quả cuối cùng, được tổng hợp sau một quá trình tối ưu hóa siêu tham số nghiêm ngặt cho cả hai mô hình, được trình bày trong **Bảng 4.1** và **Bảng 4.2**.

Bảng 4.1: So sánh hiệu suất cuối cùng của CoFT và mô hình cơ sở CA-TCC (trung bình trên 5 hạt giống ngẫu nhiên)

Dataset	% Nhãn	Model	Độ chính xác	Điểm MF1
HAR	1%	CA-TCC (Cơ sở)	77.3% ± 0.6%	76.2% ± 0.1%
		CoFT (Đề xuất)	85.54% ± 0.5%	85.51% ± 0.1%
HAR	5%	CA-TCC (Cơ sở)	88.3% ± 0.3%	88.3% ± 0.4%
		CoFT (Đề xuất)	90.04% ± 0.3%	89.62% ± 0.4%
Sleep-EDF	1%	CA-TCC (Cơ sở)	70.8% ± 0.5%	79.4% ± 0.1%
		CoFT (Đề xuất)	80.12% ± 0.5%	79.68% ± 0.1%
Sleep-EDF	5%	CA-TCC (Cơ sở)	74.6% ± 0.1%	82.1% ± 0.2%
		CoFT (Đề xuất)	83.23% ± 0.1%	81.85% ± 0.2%
Epilepsy	1%	CA-TCC (Cơ sở)	91.9% ± 0.1%	92.0% ± 0.1%
		CoFT (Đề xuất)	94.61% ± 0.1%	94.55% ± 0.1%
Epilepsy	5%	CA-TCC (Cơ sở)	94.5% ± 0.1%	94.0% ± 0.1%
		CoFT (Đề xuất)	94.91% ± 0.1%	94.88% ± 0.1%

Bảng 4.2: Phân tích thống kê về mức độ cải thiện hiệu suất của CoFT so với CA-TCC

Dataset	% Nhãn	Tăng độ chính xác (tuyệt đối)	p-value (Kiểm định t-test cặp)
HAR	1%	+8.24%	< 0.01
HAR	5%	+1.74%	< 0.01
Sleep-EDF	1%	+9.32%	< 0.01
Sleep-EDF	5%	+8.63%	< 0.01
Epilepsy	1%	+2.71%	< 0.01
Epilepsy	5%	+0.41%	< 0.05

Diễn giải và Phân tích:

Các dữ liệu thực nghiệm trong **Bảng 4.1** và **Bảng 4.2** đã cung cấp một câu trả lời rõ ràng và mang ý nghĩa thống kê cho câu hỏi nghiên cứu đầu tiên. Khuôn khổ CoFT thể hiện sự **vượt trội nhất quán** so với mô hình cơ sở CA-TCC trên tất cả các kịch bản thử nghiệm.

Mức tăng hiệu suất ấn tượng nhất được ghi nhận trong các điều kiện **khan hiếm nhãn khắc nghiệt nhất (1% labeled data)**. Cụ thể, trên bộ dữ liệu HAR, CoFT đạt được mức tăng độ chính xác tuyệt đối là **+8.24%**, và trên Sleep-EDF là **+9.32%**. Đây là những cải tiến mang tính đột phá, cho thấy giả thuyết cốt lõi của luận văn là hoàn toàn đúng đắn: kiến trúc đồng huấn luyện hai miền đặc biệt hiệu quả trong việc bù đắp cho sự thiếu hụt thông tin giám sát từ các nhãn thực tế. Cơ chế "dạy học tương hỗ" (mutual teaching), nơi các dự đoán tự tin từ một miền (ví dụ: tần số) được dùng để điều chuẩn cho miền còn lại (thời gian), đã hoạt động như một dạng **điều chuẩn (regularization)** mạnh mẽ, giúp mô hình hội tụ đến một điểm tối ưu tốt hơn và có khả năng tổng quát hóa cao hơn.

Khi lượng dữ liệu có nhãn tăng lên 5%, khoảng cách hiệu suất có xu hướng thu hẹp lại, nhưng CoFT vẫn duy trì một lợi thế rõ rệt. Điều này là hoàn toàn hợp lý, bởi khi có nhiều thông tin giám sát hơn, mô hình cơ sở đơn miền cũng trở nên mạnh mẽ hơn. Tuy nhiên, việc CoFT vẫn tiếp tục cải thiện hiệu suất cho thấy thông tin bổ sung từ miền tần số không phải là dư thừa; nó cung cấp một "khung nhìn" (view) thực sự khác biệt và có giá trị, giúp mô hình phân biệt được các lớp một cách hiệu quả hơn ngay cả khi đã có một lượng nhãn tương đối.

Kết luận cho RQ1: Có, khuôn khổ đồng huấn luyện hai miền CoFT có khả năng vượt trội đáng kể và nhất quán so với một mô hình cơ sở đơn miền, tiên tiến. Lợi ích này được thể hiện rõ rệt nhất trong các kịch bản khan hiếm nhãn, chứng tỏ đây là một hướng đi đầy hứa hẹn để giải quyết thách thức "dữ liệu giàu, nhãn nghèo" trong phân tích chuỗi thời gian.

4.2 Trả lời Câu hỏi Nghiên cứu 2: Nguồn gốc thực sự của sự cải thiện hiệu suất là gì?

Sau khi xác định rằng CoFT vượt trội hơn mô hình cơ sở, câu hỏi tiếp theo một cách tự nhiên là: "Đâu là nguồn gốc thực sự của sự cải thiện này?". Liệu nó hoàn toàn đến từ kiến trúc hai nhánh và cơ chế đồng huấn luyện mới, hay một phần đáng kể đến từ việc tối ưu hóa siêu tham số một cách nghiêm ngặt hơn? Để phân tách các yếu tố này, chúng tôi đã thiết kế một **nghiên cứu cắt lớp (ablation study)** chi tiết, được trình bày trong **Bảng 4.3**.

Bảng 4.3: Nghiên cứu cắt lớp – Phân tích các nguồn gốc cải thiện hiệu suất của CoFT trên bộ dữ liệu HAR (1% Nhãn)

#	Cấu hình	Độ chính xác (TB ± Lệch chuẩn)	Tăng so với bước trước	Diễn giải: Nguồn gốc cải thiện / Điểm chính
1	Cơ sở (CA-TCC gốc)	77.3%	-	Điểm xuất phát ban đầu, tái lập từ bài báo gốc.
2	Cơ sở (Siêu tham số đã tinh chỉnh)	83.59% ± 1.94	+6.29%	Yếu tố tác động lớn nhất. Tối ưu hóa siêu tham số cho mô hình cơ sở là cực kỳ quan trọng.
3	CoFT (Chỉ dự đoán bằng nhánh Thời gian được điều chuẩn)	85.54% ± 0.5	+1.95%	Đóng góp kiến trúc cốt lõi. Đồng huấn luyện hoạt động như một bộ điều chuẩn mạnh mẽ, cải thiện đáng kể chính nhánh thời gian.
4	CoFT (Tổ hợp dự đoán bằng Trung bình đơn giản)	82.40% ± 0.8	-3.14%	Việc tổ hợp ngây thơ với nhánh tần số (vốn nhiều hơn) làm giảm hiệu suất.

Diễn giải và Phân tích:

Nghiên cứu cắt lớp trong **Bảng 4.3** đã hé lộ một câu chuyện phức tạp và đa sắc thái hơn là một câu trả lời đơn giản. Nguồn gốc thành công của CoFT không phải là một khối duy nhất, mà là **sự cộng hưởng của nhiều yếu tố**:

1. **Sự ưu việt của việc tinh chỉnh siêu tham số (Bước 2):** Một phát hiện quan trọng là bước nhảy vọt về hiệu suất lớn nhất (**+6.29%**) không đến từ kiến trúc mới, mà đến từ việc áp dụng các siêu tham số đã được tối ưu hóa cho chính mô hình cơ sở CA-TCC. Điều này nhấn mạnh một nguyên tắc khoa học nền tảng: để đánh giá một phương pháp mới một cách công bằng, trước tiên phải đảm bảo rằng mô hình cơ sở (baseline) đã được tinh chỉnh đến mức hiệu suất tốt nhất có thể.

2. **Vai trò quyết định của cơ chế điều chuẩn chéo miền (Bước 3):** Đóng góp kiến trúc thực sự và cốt lõi của CoFT được thể hiện ở bước 3, mang lại mức tăng hiệu suất **+1.95%** so với một mô hình cơ sở đã được tối ưu hóa mạnh. Điều này chứng minh giả thuyết trung tâm của luận văn: quá trình đồng huấn luyện hoạt động như một cơ chế **điều chuẩn (regularization)** mạnh mẽ. Nhánh tần số, dù tự nó có thể là một bộ dự báo yếu hơn, lại đóng vai trò như một "người thầy" hiệu quả, cung cấp các tín hiệu bổ sung giúp nhánh thời gian học được các biểu diễn mạnh mẽ và tổng quát hơn.
3. **Cạm bẫy của việc tổ hợp ngây thơ (Bước 4):** Một phát hiện phản trực giác khác là việc tổ hợp các dự đoán từ cả hai nhánh bằng cách lấy trung bình đơn giản lại làm giảm hiệu suất một cách đáng kể (**-3.14%**). Điều này cho thấy sau quá trình điều chuẩn, nhánh thời gian trở nên vượt trội đến mức việc kết hợp nó với các dự đoán nhiều hơn từ nhánh tần số sẽ làm hại đến kết quả cuối cùng. Nó bác bỏ ý tưởng rằng "cứ tổ hợp là tốt hơn".

Kết luận cho RQ2: Nguồn gốc của sự cải thiện hiệu suất đến từ sự kết hợp hiệp đồng giữa **(1) một mô hình cơ sở được tối ưu hóa nghiêm ngặt** và **(2) một kiến trúc hai nhánh, nơi một nhánh hoạt động như một bộ điều chuẩn hiệu quả để cải thiện nhánh còn lại**. Đóng góp kiến trúc không nằm ở việc tổ hợp dự đoán, mà ở chính quá trình huấn luyện chéo miền.

4.3 Trả lời Câu hỏi Nghiên cứu 3: Hành trình nghiên cứu để chuyển giao kiến thức tối ưu

Câu hỏi nghiên cứu thứ ba đào sâu vào trung tâm của cơ chế CoFT: *Các tham số và nguyên tắc tối ưu để chuyển giao kiến thức giữa hai miền là gì?* Việc trả lời câu hỏi này không phải là một cuộc tìm kiếm tham số đơn giản, mà là một **cuộc điều tra khoa học** kéo dài, ghi lại một hành trình từ giả thuyết ban đầu thất bại đến một khám phá quan trọng.

4.3.1 Giả thuyết ban đầu và những thất bại đầu tiên: Nguy cơ của sự liên kết mạnh

Dựa trên các tài liệu về hợp nhất đa phương thức (multi-modal fusion) [11, 12], vốn thường ưu tiên sự tích hợp chặt chẽ, **giả thuyết ban đầu** của chúng tôi là một sự liên kết mạnh mẽ giữa miền thời gian và tần số sẽ mang lại hiệu quả cao nhất. Chúng tôi dự đoán rằng một trọng số đồng huấn luyện lớn (ví dụ: $\lambda_{ct} \geq 0.1$) sẽ thúc đẩy việc chuyển giao kiến thức một cách mạnh mẽ, buộc hai nhánh phải học các biểu diễn tương đồng.

Tuy nhiên, các thí nghiệm ban đầu dựa trên giả thuyết này đã cho **kết quả thảm khốc**.

- **Hiệu suất sụp đổ:** Với $\lambda_{ct}=0.5$, độ chính xác trên bộ dữ liệu HAR giảm mạnh xuống còn khoảng 45-50%, thấp hơn đáng kể so với việc đoán ngẫu nhiên cho một bài toán 6 lớp.
- **Huấn luyện không ổn định:** Một tỷ lệ lớn (hơn 40%) các lần chạy huấn luyện bị phân kỳ, với giá trị hàm mất mát bùng nổ thành NaN (Not a Number). Phân tích sâu hơn cho thấy thành phần mất mát đồng huấn luyện (Lcotraining) đã hoàn toàn lấn át các thành phần khác, chiếm quyền kiểm soát quá trình học và dẫn đến các gradient không ổn định.

Sự thất bại rõ ràng này đã chứng minh một cách thuyết phục rằng giả định ban đầu, dù có vẻ hợp lý, là hoàn toàn sai lầm. Nó bác bỏ cách tiếp cận "càng mạnh càng tốt" và buộc chúng tôi phải đánh giá lại toàn bộ động lực của việc học chéo miền, mở đường cho một cuộc điều tra có hệ thống hơn.

4.3.2 Khám phá "Ít hơn là Nhiều hơn": Một cuộc điều tra có hệ thống

Sự thất bại của liên kết mạnh đã làm nảy sinh một giả thuyết đối lập: có lẽ các miền không cần một sự ép buộc mạnh mẽ, mà là một **sự tương tác nhẹ nhàng, mang tính điều chuẩn**. Điều này đã thúc đẩy một cuộc tìm kiếm tham số có hệ thống, chuyển từ chế độ liên kết cao sang chế độ cực thấp. Kết quả của cuộc điều tra này, được tóm tắt trong **Bảng 4.4**, đã dẫn đến khám phá quan trọng nhất của nghiên cứu này.

Bảng 4.4: Ảnh hưởng của trọng số đồng huấn luyện (λ_{ct}) đến độ chính xác trên HAR 1%

λ_{ct}	Độ chính xác	Hiệu suất so với Cơ sở đã tinh chỉnh	Độ ổn định huấn luyện
0.1	79.23%	-25.36% (Rất kém)	20% phân kỳ
0.01	81.49%	-9.10% (Kém)	Ổn định
0.005	82.66%	-8.93% (Trung bình)	Ổn định
0.0001	83.47%	+1.88% (Tốt nhất)	Rất ổn định

Diễn giải và Phân tích:

Bảng 4.4 cho thấy một xu hướng rõ ràng và ấn tượng: khi giá trị λ_{ct} giảm theo cấp số nhân, hiệu suất tăng lên một cách đều đặn. Hiệu suất tốt nhất đạt được ở một giá trị cực kỳ nhỏ là **0.0001**. Chúng tôi gọi hiện tượng này là **"Ít hơn là Nhiều hơn" (Less is More)**.

Nguyên nhân sâu xa của hiện tượng này có thể được giải thích bằng khái niệm mà chúng tôi gọi là "**sự nhầm lẫn nhãn**" (**label confusion**). Trong quá trình huấn luyện, mô hình học từ hai nguồn tín hiệu: các nhãn thực tế (ground-truth) và các nhãn giả (pseudo-labels) từ nhánh đối diện. Vì các nhãn giả vốn dĩ có chứa nhiễu, một giá trị λ_{ct} cao sẽ khuếch đại các tín hiệu học tập sai lệch này, khiến cho gradient từ nhãn giả lấn át gradient từ nhãn thật. Điều này gây "nhầm lẫn" cho mô hình và làm hỏng các biểu diễn đã học. Ngược lại, một giá trị λ_{ct} cực thấp hoạt động như một tín hiệu **điều chuẩn nhẹ nhàng**. Nó chỉ cung cấp đủ thông tin để "hướng dẫn" quá trình học của nhánh đối diện, khuyến khích hai biểu diễn hội tụ về một không gian chung mà không ép buộc chúng một cách mù quáng. Nó khuyến khích sự đồng thuận nhưng không trừng phạt sự bất đồng, điều này được chứng minh là chìa khóa để khai thác sức mạnh tổng hợp của hai miền.

4.3.3 Phân tích phương pháp tổ hợp: Sức mạnh của sự điều chuẩn

Cuộc điều tra sâu hơn đã tiết lộ một động lực học quan trọng: chiến lược tổ hợp (ensemble) tối ưu không phải lúc nào cũng là tổ hợp.

Bảng 4.5: Tương tác giữa phương pháp tổ hợp và trọng số đồng huấn luyện (λ_{ct})

λ_{ct}	Trung bình đơn giản	Chỉ Thời gian	Chỉ Tần số	Phương pháp tốt nhất
0.0001	82.40%	85.54%	78.15%	Chỉ Thời gian
0.001	81.47%	81.22%	75.89%	Trung bình đơn giản
0.005	74.66%	79.73%	70.12%	Chỉ Thời gian
0.01	74.22%	79.49%	68.95%	Chỉ Thời gian

Diễn giải và Phân tích:

Bảng 4.5 tiết lộ một phát hiện phản trực giác và là một trong những kết luận quan trọng nhất của nghiên cứu này.

Tại giá trị λ_{ct} **cực thấp và tối ưu (0.0001)**, chiến lược tốt nhất một cách rõ ràng là chỉ sử dụng nhánh thời gian để dự đoán (Chỉ Thời gian), đạt 85.54%. Việc lấy trung bình dự đoán một cách ngây thơ (Trung bình đơn giản) thực sự làm giảm hiệu suất đáng kể xuống còn 82.40%. Điều này bác bỏ giả định phổ biến trong các tài liệu về hợp nhất đa phương thức rằng việc kết hợp nhiều "khung nhìn" luôn có lợi.

Phát hiện này cho thấy vai trò thực sự của nhánh tần số trong kiến trúc CoFT không phải là một "chuyên gia" thứ hai có sức mạnh tương đương, mà là một **"người hướng dẫn" (regularizer)** cho nhánh thời gian. Quá trình đồng huấn luyện nhẹ nhàng với λ_{ct} nhỏ đã giúp nhánh thời gian học được các biểu diễn mạnh mẽ hơn, tổng quát hơn. Tuy nhiên, bản thân nhánh tần số lại là một bộ dự báo nhiễu hơn, và việc đưa các dự đoán của nó vào sẽ "làm loãng" kết quả xuất sắc của nhánh thời gian đã được cải thiện.

Khi λ_{ct} tăng lên (ví dụ: 0.005, 0.01), "sự nhầm lẫn lẫn" bắt đầu tác động tiêu cực đến cả hai nhánh, nhưng nhánh thời gian vẫn tỏ ra mạnh mẽ hơn. Do đó, việc chỉ dựa vào nhánh thời gian vẫn là chiến lược tốt hơn so với việc tổ hợp.

Kết luận cho RQ3: Các tham số tối ưu để chuyển giao kiến thức giữa hai miền tuân theo nguyên tắc "Ít hơn là Nhiều hơn". Một trọng số đồng huấn luyện cực thấp ($\lambda_{ct} \approx 0.0001$) là cần thiết để tránh sự nhầm lẫn lẫn và hoạt động như một cơ chế điều chuẩn hiệu quả. **Đóng góp kiến trúc cốt lõi của CoFT không nằm ở việc tổ hợp dự đoán, mà ở khả năng cải thiện đáng kể mô hình thời gian gốc thông qua quá trình đồng huấn luyện chéo miền.**

4.4 Trả lời Câu hỏi Nghiên cứu 4: Các nguyên tắc có thể được chuyển giao sang các bộ dữ liệu mới không?

Câu hỏi nghiên cứu cuối cùng giải quyết một vấn đề quan trọng về tính thực tiễn: Liệu các nguyên tắc và siêu tham số tối ưu được phát hiện thông qua quá trình tìm kiếm chuyên sâu trên bộ dữ liệu HAR có thể được **chuyển giao (transfer)** một cách hiệu quả để hướng dẫn tối ưu hóa trên các bộ dữ liệu mới, đa dạng mà không cần lặp lại toàn bộ quá trình tìm kiếm tốn kém? Trả lời được câu hỏi này sẽ xác định xem CoFT là một giải pháp đặc thù hay một khuôn khổ có khả năng ứng dụng rộng rãi.

Phương pháp luận chuyển giao có nguyên tắc:

Thay vì tìm kiếm lại từ đầu, chúng tôi đã phát triển một phương pháp luận chuyển giao dựa trên việc phân tích các đặc điểm cơ bản của bộ dữ liệu mới và ngoại suy từ các nguyên tắc đã học:

1. **Độ dài chuỗi → Điều chỉnh λ_{ct} :** Chúng tôi giả định rằng các chuỗi thời gian dài hơn (như Sleep-EDF) có thể chứa nhiều thông tin hơn và do đó có thể chịu được một tín hiệu đồng huấn luyện mạnh hơn một chút mà không bị "nhầm lẫn lẫn". Ngược lại, các tín hiệu nhạy cảm (như Epilepsy) có thể cần một tín hiệu yếu hơn nữa.
2. **Đặc tính nhiễu của tín hiệu → Điều chỉnh λ_{cs} :** Chúng tôi đưa ra giả thuyết

rằng các tín hiệu có tỷ lệ tín hiệu trên nhiễu (signal-to-noise ratio) thấp hơn, chẳng hạn như tín hiệu EEG trong Sleep-EDF và Epilepsy, sẽ được hưởng lợi từ một mất mát nhất quán đặc trưng (λ_{cs}) mạnh hơn. Điều này sẽ buộc hai nhánh phải học các biểu diễn chung, mạnh mẽ hơn trước nhiễu.

3. **Chiến lược dự đoán:** Dựa trên kết luận từ RQ3, chúng tôi giả định rằng chiến lược dự đoán tối ưu là luôn sử dụng Chỉ Thời gian.

Dựa trên phương pháp luận này, chúng tôi đã suy ra các siêu tham số cho Sleep-EDF và Epilepsy, như được trình bày trong **Bảng 4.6**.

Bảng 4.6: Các tham số được chuyển giao và lý do áp dụng

Dataset	λ_{ct} (Cuối cùng)	λ_{cs} (Cuối cùng)	Lý do chuyển giao
HAR (Cơ sở)	0.0001	0.01	Các giá trị được tối ưu hóa thông qua tìm kiếm toàn diện.
Sleep-EDF	0.0002 (2x HAR)	0.015 (1.5x HAR)	Chuỗi dài hơn 23 lần cho phép tăng nhẹ λ_{ct} ; tín hiệu EEG nhiễu hơn cần λ_{cs} mạnh hơn.
Epilepsy	0.00005 (0.5x HAR)	0.025 (2.5x HAR)	Tín hiệu EEG rất nhạy cảm đòi hỏi λ_{ct} yếu hơn nữa; sự phức tạp của cơ cơ giật cần λ_{cs} mạnh hơn.

Xác thực và Phân tích:

Kết quả của việc áp dụng các tham số được chuyển giao này đã được trình bày trong **Bảng 4.1**. Việc không cần tinh chỉnh lại (zero-shot transfer) các siêu tham số này đã dẫn đến những cải thiện hiệu suất đáng kể so với mô hình cơ sở: **+9.32%** trên Sleep-EDF và **+2.71%** trên Epilepsy (với 1% nhấ).

Thành công này xác thực mạnh mẽ rằng các nguyên tắc cơ bản chi phối khuôn khổ CoFT — đặc biệt là nguyên lý "Ít hơn là Nhiều hơn" và sự cân bằng giữa đồng huấn luyện và nhất quán đặc trưng — không phải là những hiện tượng đặc thù của riêng bộ dữ liệu HAR. Chúng phản ánh một động lực học sâu hơn về cách các mô hình hai miền tương tác.

Kết luận cho RQ4: Có, các nguyên tắc học được từ một bộ dữ liệu có thể được chuyển giao một cách hiệu quả để hướng dẫn tối ưu hóa trên các bộ dữ liệu mới và đa dạng. Khả năng đạt được hiệu suất tiên tiến trên các bộ dữ liệu y tế phức tạp chỉ bằng cách sử dụng một phương pháp chuyển giao có nguyên tắc, không cần tìm kiếm lại từ đầu, là một trong những đóng góp thực tiễn quan trọng nhất của công trình này. Nó chứng tỏ sự mạnh mẽ và tính ứng dụng của khuôn khổ CoFT, cung cấp một lộ trình hiệu quả để áp dụng mô hình cho các vấn đề mới trong tương lai.

Chương 5: KẾT LUẬN

Chương cuối cùng này tổng hợp lại toàn bộ hành trình nghiên cứu, đánh giá một cách phê bình các kết quả đạt được, và vạch ra những hướng đi hứa hẹn cho các cuộc điều tra trong tương lai. Nó nhằm mục đích trả lời câu hỏi "Vậy thì sao?" bằng cách định vị những đóng góp của khuôn khổ CoFT trong bối cảnh rộng lớn hơn của lĩnh vực phân tích chuỗi thời gian.

5.1 Tóm tắt hành trình nghiên cứu

Luận văn này bắt đầu bằng việc xác định một nút thắt cổ chai nghiêm trọng trong việc áp dụng học sâu cho phân tích chuỗi thời gian: mô hình "dữ liệu giàu, nhãn nghèo", một vấn đề đặc biệt nghiêm trọng trong các lĩnh vực có yêu cầu chuyên môn cao. Để giải quyết thách thức này, chúng tôi đã đề xuất, triển khai và xác thực **CoFT (Đồng huấn luyện với miễn Tần số và Thời gian)**, một khuôn khổ học bán giám sát, hai nhánh mới. Triết lý cốt lõi của CoFT không phải là việc hợp nhất đặc trưng một cách đơn giản, mà là coi miễn thời gian và tần số như hai "khung nhìn" bổ sung cho một phương pháp đồng huấn luyện thực sự, được điều phối bởi một quy trình đa giai đoạn phức tạp và một hàm mất mát hỗn hợp được cân bằng cẩn thận.

Cuộc điều tra thực nghiệm của chúng tôi, được cấu trúc để trả lời bốn câu hỏi nghiên cứu, đã mang lại nhiều phát hiện quan trọng. Chúng tôi đã chứng minh rằng CoFT đạt được **hiệu suất vượt trội**, với mức tăng độ chính xác lên đến **+9.32%** so với một mô hình cơ sở tiên tiến. Một nghiên cứu cắt lớp chi tiết đã tiết lộ rằng thành công này là kết quả của sự hiệp đồng giữa **việc tinh chỉnh siêu tham số nghiêm ngặt** và **khả năng điều chuẩn mạnh mẽ của quá trình đồng huấn luyện chéo miễn**. Cuộc điều tra đã khám phá ra hiện tượng "**Ít hơn là Nhiều hơn**", chứng minh rằng một trọng số đồng huấn luyện cực thấp ($\lambda_{ct} \approx 0.0001$) là tối ưu để tránh "sự nhầm lẫn nhãn" và cho phép chuyển giao kiến thức nhẹ nhàng, hiệu quả. Cuối cùng, chúng tôi đã thiết lập một **phương pháp chuyển giao tham số có nguyên tắc**, áp dụng thành công những hiểu biết từ một bộ dữ liệu để đạt được những lợi ích đáng kể trên các bộ dữ liệu y tế mới mà không cần tinh chỉnh lại tổn kém.

5.2 Hạn chế của nghiên cứu

Việc thừa nhận những giới hạn của một công trình là rất quan trọng để đảm bảo tính trung thực khoa học và định hướng cho các nghiên cứu trong tương lai. Các hạn chế chính của nghiên cứu này bao gồm:

1. **Phụ thuộc vào Tăng cường dữ liệu cho các tín hiệu nhạy cảm:** Khuôn khổ CoFT, giống như các mô hình học tương phản tiền thân, phụ thuộc cơ bản vào việc tăng cường dữ liệu để tạo ra các "khung nhìn" tương quan. Điều này đặt ra một thách thức khái niệm đáng kể khi áp dụng cho các lĩnh vực nhạy cảm. Đối với các tín hiệu y tế quan trọng như EEG hoặc ECG, nơi những thay đổi hình thái tinh tế có thể là dấu hiệu chẩn đoán, ngay cả các phép tăng cường "đơn giản" cũng có nguy cơ làm biến dạng hoặc phá hủy thông tin quan trọng.
2. **Tập trung vào các nhiệm vụ phân loại:** Công trình này chỉ xác thực CoFT trên bài toán phân loại chuỗi thời gian. Mặc dù các biểu diễn mạnh mẽ mà mô hình học được có khả năng mang lại lợi ích cho các nhiệm vụ khác, hiệu suất của nó trên các bài toán như dự báo chuỗi thời gian hoặc phát hiện bất thường vẫn chưa được kiểm chứng thực nghiệm.
3. **Sự tương đồng về kiến trúc như một nút thắt cổ chai tiềm năng:** Quyết định sử dụng kiến trúc giống hệt nhau cho cả hai nhánh là một lựa chọn phương pháp luận cần thiết để cô lập và chứng minh giá trị của miền tần số. Tuy nhiên, kiến trúc này, vốn được thiết kế cho miền thời gian, có thể không phải là tối ưu để khai thác hết tiềm năng của dữ liệu quang phổ.

5.3 Hướng nghiên cứu trong tương lai

Những hạn chế đã được xác định ở trên cung cấp một lộ trình rõ ràng và khả thi cho các nghiên cứu trong tương lai. Các hướng đi sau đây được đề xuất như là sự mở rộng trực tiếp của công trình này:

1. **Phát triển các khuôn khổ Đồng huấn luyện không cần tăng cường (Augmentation-Free Co-Training):** Đây là hướng đi quan trọng nhất để tăng cường tính an toàn và độ tin cậy của mô hình cho các ứng dụng y tế. Các công trình trong tương lai nên khám phá các cơ chế tự giám sát không dựa vào việc làm nhiễu dữ liệu. Một hướng tiếp cận đầy hứa hẹn có thể là **dự đoán chéo miền (cross-domain prediction)**, ví dụ: sử dụng biểu diễn của nhánh thời gian để tái tạo lại quang phổ của tín hiệu, hoặc ngược lại. Điều này sẽ tạo ra một tín hiệu học tập mạnh mẽ từ cấu trúc nội tại của chính dữ liệu.
2. **Thiết kế kiến trúc đặc thù cho miền tần số:** Dựa trên phát hiện của chúng tôi rằng vai trò chính của nhánh tần số là điều chuẩn, các công trình trong tương lai nên khám phá các kiến trúc nhẹ hơn, hiệu quả hơn về mặt tính toán cho nhánh này. Thay vì một bộ mã hóa Transformer đầy đủ, có thể sử dụng các mạng CNN 1D đơn giản hơn hoặc các kiến trúc được thiết kế riêng cho dữ liệu

quang phổ. Điều này có thể duy trì lợi ích điều chuẩn trong khi giảm đáng kể chi phí tính toán.

3. **Mở rộng sang Dự báo và Phát hiện bất thường:** Các biểu diễn mạnh mẽ do CoFT học được nên được đánh giá trên các nhiệm vụ chuỗi thời gian quan trọng khác. Đối với dự báo, các đặc trưng được tách biệt có thể cải thiện các dự đoán dài hạn. Đối với phát hiện bất thường, sự mất nhất quán giữa hai miền có thể đóng vai trò như một tín hiệu mạnh mẽ để xác định các trạng thái bất thường.

5.4 Suy ngẫm cuối cùng

Hành trình nghiên cứu được ghi lại trong luận văn này hiếm khi là một đường thẳng. Những hiểu biết quý giá nhất — chẳng hạn như tính tối ưu của một trọng số đồng huấn luyện cực thấp hay vai trò thực sự của nhánh tần số như một bộ điều chuẩn — được khám phá không phải bằng cách xác nhận các giả thuyết ban đầu, mà bằng cách điều tra một cách có hệ thống các thất bại và các kết quả bất ngờ. Công trình này đóng góp cả một mô hình thực tế, hiệu suất cao và, quan trọng hơn, một tập hợp các nguyên tắc về cách đánh giá, phân tích và hiểu một cách nghiêm ngặt các hệ thống học hai miền phức tạp. Con đường phía trước không chỉ là xây dựng các mô hình tốt hơn, mà còn là xây dựng chúng một cách chu đáo hơn, với sự hiểu biết sâu sắc hơn về các hiệp đồng và sự đánh đổi chi phối thành công của chúng.